



BIG DATA

AULA 1



Prof. Armando Kolbe Júnior

CONVERSA INICIAL

A área da Tecnologia da Informação (TI) é uma das principais fornecedoras de ferramentas para facilitar a racionalização de trabalhos desenvolvidos em praticamente todas as áreas do conhecimento humano, a ponto de, muitas vezes, seus técnicos deixarem esquecidas em algum escaninho propostas para que elas sejam aplicadas de forma reflexiva na própria área de TI. O *Big Data* é uma nova tecnologia e, por mais paradoxal que possa parecer, tem seus primeiros reflexos utilizados na própria área de TI, buscando racionalização de procedimentos e um dos seus apelos mais atrativos: a redução de custos.

Figura 1 – *Big Data*



Crédito: Rafal Olechowski/Shutterstock.

O tema *Big Data* será aqui tratado de forma mais ampla, sendo os conhecimentos sugeridos aplicáveis a quaisquer áreas de conhecimento criadas pelo ser humano. Há quem considere que a área de administração de empresas seja uma das mais favorecidas, o que não está tão longe da realidade, mas que não se apresenta de forma tão ostensiva como possa parecer.

A área *Big Data* é altamente influente em muitos aspectos diversificados, criando ferramentas altamente eficazes tanto para atendimento de aspectos administrativos quanto de processos tecnológicos, com destaque para um favorecimento diferenciado da área de tomada de decisões.

O contexto de aplicação do fenômeno *Big Data* tem seu início nas áreas relativas aos processos de gestão da tecnologia da informação e se espalha pelos sistemas de informação gerencial (SIG). Os diferentes componentes trazem a criação de um conjunto diferenciado de metodologias inovadoras, utilizadas em procedimentos aplicáveis em outras áreas da informação. O questionamento sobre se o fenômeno *Big Data* é uma tecnologia, um processo, uma metodologia, não poderia faltar e a resposta imediata é: nenhuma dessas classificações.

Para melhor compreender esse fenômeno, é necessário aprofundar o nível de abstração para considerar e compreender que ele representa um conjunto de dados captados, armazenados, processados, transformados em informações.

Todo esse volume é colocado à disposição das pessoas e dos diferentes processos que exigem esses dados para melhoria das funções que cada uma delas desenvolve. Os resultados, partindo dos mesmos dados, podem ser totalmente diferentes, sendo a intervenção humana o principal agente externo, que altera os resultados que podem ser considerados como um sistema aberto, como postula Bertalanffy (2014), aqueles que sofrem influência do meio ambiente externo.

TEMA 1 – HISTÓRIA E CONSIDERAÇÕES ATUAIS

1.1 Surgimento

Tudo o que vivenciamos tem uma razão para seu surgimento. A evolução leva qualquer proposta a atingir o que é denominado “estado da arte”, como ela é vista dentro da perspectiva atual. Tal fato não poderia ser diferente com o fenômeno *Big Data*.

Taurion (2013) considera como a definição mais apropriada para o tema aquela estabelecida na data de seu surgimento, quando o fenômeno foi identificado como a regulação das atividades de captura, armazenamento, transformação e utilização de dados aos quais a empresa pode ter acesso, na grande rede, captados de forma livre ou como resultado de atividades extensivas de Inteligência Competitiva (IC).



A IC é um termo sofisticado para atividades de espionagem industrial (Gomes; Braga, 2017). Diversos aplicativos utilizam tais dados com os mais diferentes objetivos, entre os quais a obtenção de elementos de apoio à tomada de decisão, um dos mais importantes, por representar retorno para a empresa caso ela utilize os resultados de transformação para se tornar mais ágil, o que pode lhe conferir elevada competitividade no mercado.

A constituição do fenômeno como uma área de saber, e atualmente, a caminho de se tornar uma área do conhecimento, representa uma nova era, com o surgimento de novos empregos na área de TI (analistas de dados) e novas funções delegadas aos gestores que trabalham com informações gerenciais estratégicas para a empresa.

1.2 Estado da arte

Quando queremos abordar o tema “estado da arte”, especificadamente em *Big Data*, necessitamos entender o que e onde ocorre esse momento, pois, de alguma forma, a evolução constante das tecnologias está, naturalmente, atrelada aos dados e informações.

Sob quaisquer aspectos que possam ser analisados os dados crescem em valor. Eles facilitam atingir resultados altamente positivos, com alterações significativas sobre como a economia e a ciência utilizam estes dados no desenvolvimento das descobertas de novos conhecimentos.

Vamos tomar como exemplo a área administrativa de uma empresa do mercado corporativo. Em seu interior os departamentos de marketing reúnem pessoas que trabalham com a “*presença*” da empresa e reafirmação de sua marca em um mercado altamente competitivo, no qual o vai e vem de empresas se sucedem em uma velocidade. Nesta área, o *Big Data* tem grande importância e os dados são enxergados como o insumo básico, sem o qual não seria possível obter uma visão sobre como andam os negócios da empresa e sobre o perfil dos clientes.

A importância de dados sobre estes dois tópicos é inequívoca. As proposições de valor e busca de modelos de negócios, permitem que a empresa crie produtos que atendam os desejos e as necessidades de um público cada vez mais exigente. Dados relativos a estas áreas são importantes e demandam atividades de análise que somente sobrevivem em meio a um grande volume de dados, transformados em informações importantes. O estado da arte atual no



que diz respeito ao *Big Data* pode ser reconhecido de acordo com a constatação de um conjunto formado por:

- Pessoas que analisam com diferentes olhares preditivos e prescritivos o comportamento do mercado;
- Setores especificamente voltados para análise de dados;
- Sofisticados sistemas de captação de dados, seu armazenamento em grandes repositórios, recuperação seletiva e disseminação;
- Necessidade de preservação digital;
- Maiores cuidados com diferentes características dos dados já convertidos em informações significativas para a empresa.

Na sequência do estudo serão analisadas os 10 Vs do *Big Data*, que são o volume, a variedade, a velocidade, a volatilidade, a visualização, a viralidade, o valor, a veracidade, a validade e vulnerabilidade.

Figura 2 – Os 10 Vs do *Big Data*

Características de <i>Big Data</i> , questões e desafios		
Volume	➡	Escala de dados
Valor	➡	Utilidade de dados na tomada de decisão
Velocidade	➡	Processamento de dados: lote e fluxo
Veracidade	➡	Qualidade e precisão dos dados
Visualização	➡	Recuperação de dados aos usuários
Vulnerabilidade	➡	Falta de cuidado na estruturação das grandes bases de dados
Volatilidade	➡	Durabilidade dos dados
Viralidade	➡	Alguma informação que causa impacto
Validade	➡	Dados corretamente compreensíveis
Variedade	➡	Heterogeneidade de dados: estruturado, semiestruturado, não estruturado

Fonte: Adaptado de livti.com.br.

Saiba mais

- Confirme algumas das colocações deste tema assistindo ao vídeo “What Exactly Is *Big Data* and Why Should You Care?”, da Forbes. Disponível em: <<https://www.youtube.com/watch?v=jGhRiwGHh30>>.
- Saiba mais o que Mozzato e Grzybovski pensam sobre a análise de dados colocada como nova competência para os profissionais. Disponível em: <<http://www.scielo.br/pdf/rac/v15n4/a10v15n4.pdf>>.
- Conheça um pouco mais sobre uma das áreas marginais do tema *Big Data* e de grande importância no artigo “Inteligência competitiva: fator-chave



para o sucesso das organizações no novo milênio”, de Rogério A. Lana. Disponível em: <<http://www.inteligenciacompetitivarev.com.br/ojs/index.php/rev/article/viewFile/19/38>>.

1.3 Tema de pesquisa sobre este tema

Considere desenvolver uma pesquisa que lhe permita avaliar qual o efeito que o *Big Data* pode ter como ferramenta altamente estratégica na análise de comportamento do mercado.

TEMA 2 – *BIG DATA* – VOLUME E VARIEDADE

2.1 Volume


O volume está diretamente relacionado a maior ou menor quantidade de dados resultantes do desenvolvimento das atividades de busca. Elas se dividem em busca (*data mining*¹), armazenamento (*data warehouse*²), *preservação digital* e conversão de dados em informações úteis para o propósito que motivou o levantamento efetivado (*data Analysis*³) e disseminação dos dados armazenados, que equivale à entrega dessas informações para departamentos (usuários finais) ou para a comunidade em casos de pesquisas científicas.

¹ Essa é uma expressão inglesa relacionada à informática e tecnologias, muito utilizada em *Big Data*, que significa “mineração de dados”.

² Sistema de computação usado no armazenamento de informações e atividades de uma empresa, organização em bancos de dados.

³ Processo de avaliação de dados que se utiliza de raciocínio analítico e lógico para examinar cada componente dos dados fornecidos.

Figura 3 – Fontes de dados para o *data warehouse*



Fonte: Adaptado de arquivo.devmedia.com.br.

Uma primeira constatação quando falamos sobre *Big Data* diz respeito ao elevado volume de dados existentes. A atividade de coleta continuou com o mesmo propósito, mas com utilização de um arsenal de novas tecnologias, que acompanham a acelerada evolução dos motores de busca.

Essa coleta de dados brutos se divide em conteúdo aproveitável e aqueles considerados como lixo eletrônico que, infelizmente, apresentam volume muito maior. Já relatamos anteriormente o uso da IC, bem como referenciamos à criação de uma nova profissão, o analista de dados.

O refinamento desses dados brutos é uma primeira necessidade para que somente então, na sequência, eles possam ser reunidos de forma a produzir informações importantes para a empresa. Tais dados são entregues já “mastigados” para que outros setores da empresa o utilizem para melhoria da qualidade dos serviços desenvolvidos.

Agora em tempos de terceirização de atividades dos departamentos de TI, adotada por muitas empresas, a atividade pode ser terceirizada, exigindo cuidados complementares, além daquele da perda da propriedade de dados importantes para a empresa.

2.2 Variedade

Anteriormente, nos referenciamos ao alto volume de dados necessários para que pessoas interessadas na solução de diferentes problemas tenham maior segurança para tomada de decisões, um dos principais objetivos na preparação de informações com base nos dados levantados. Há um primeiro



estudo no desenvolvimento de atividades *Big Data*: questões de confiança nas fontes de dados.

Superado esse primeiro obstáculo, os metabuscadores (que buscam informações em diversos mecanismos de busca simultaneamente) e os buscadores trazem elevado volume. Os buscadores estão cada vez mais sofisticados e permitem filtragem apoiada no “bom conceito” da localidade na qual o dado foi encontrado, o que pode diminuir sensivelmente a obtenção de lixo eletrônico.

Os documentos recuperados podem aparecer em uma variedade de formatos: não estruturados; parcialmente estruturados; e altamente estruturados. Nesse ponto, o que nos interessa são “dados brutos”, tais como idade dos componentes de uma determinada população sob análise ou qualquer outro indicativo de interesse para atender a necessidades pontuais. Maior ou menor estruturação depende da funcionalidade esperada com a coleta desses dados.

O envolvimento tecnológico é necessário e imperativo, sem o qual o levantamento de dados não tem significado, por não ter pessoas responsáveis pela leitura, interpretação, formatação e estruturação de tais dados. Todos os elementos coletados devem ser submetidos a uma verificação inicial, que tem como objetivo evitar o lixo eletrônico ou o rompimento de qualquer aspecto legal que protege a propriedade intelectual.

Os dados recuperados podem ser enquadrados em alguma categoria e classificados por ela (por exemplo: pesquise quantas pessoas existem em Curitiba e Região Metropolitana que desejam fazer um curso de inglês). Essa mesma pesquisa pode ser corroborada pela submissão de um questionário. Os dados assim recuperados podem estarem divididos em diferentes mídias: textos digitais, áudio, vídeo, *blogs*, páginas pessoais, resultados de aplicação de formulários.

Após a coleta, é importante que os dados localizados tragam informações sobre eles mesmos. Para atingir esse objetivo, surge a necessidade de outra atividade envolvida: a criação de dicionários que tragam informações sobre os dados que estão sendo coletados (metadados). A área de metadados é estudada em particular, devido às suas características particulares e extensão do tema.

Saiba mais

- Saiba um pouco mais sobre as consequências do aumento de volume de dados disponíveis/armazenados no artigo “Conteúdo digital dobra a cada dois anos no mundo”, da revista Exame. Disponível em: <<https://exame.com/tecnologia/conteudo-digital-dobra-a-cada-dois-anos-no-mundo/>>.
- Acesse um resumo o livro *A vida digital*, de Nicholas Negroponte. Disponível em: <<https://pedagogiaaopedaletra.com/resumo-do-livro-a-vida-digital/>>.

2. 3 Tema de pesquisa sobre este tema

Considere desenvolver uma pesquisa em que possa obter dados que vão lhe dar maior compreensão e facilitar a montagem de um artigo de opinião sobre os efeitos sociais que podem provocar o crescimento do volume de dados.

TEMA 3 – *BIG DATA* – VELOCIDADE E VOLATILIDADE

3.1 A velocidade no *Big Data*

Quando desviamos nossa atenção para o *Big Data*, é comum pensar, de forma imediata, em um elevado volume de dados que são utilizados para melhoria de comportamentos e atitudes que a empresa tem com os seus colaboradores, nos mais diversos níveis. Para os departamentos de TI, outra preocupação tem lugar: qual estrutura física possibilitaria maior rapidez de acesso?

A necessidade de um elevado tempo de resposta é uma preocupação que está na base da estruturação física das bases de dados, nas quais os dados serão inseridos (quando do levantamento de dados), e na utilização de mecanismos de busca com o melhor tempo de resposta e qualidade na validação do que está sendo enviado aos buscadores. Armazenados fisicamente em provedores, a qualidade dos sistemas de informações gerenciais (SIG) entra em foco e também deve devolver as solicitações no menor tempo possível (quando da pesquisa pelos usuários finais).

O espaço para esse armazenamento cresce de maneira exponencial e tende a aumentar um mesmo conteúdo quando se imagina o registro e a



replicação de dados não estruturados (áudio, vídeos e textos escritos em formato digital) com cuidados adicionais quanto à preservação digital necessária. A multiplicidade de fontes diferenciadas pode ocasionar uma degradação nos tempos de resposta, caso o SIG responsável não tenha sido bem projetado para evitá-la.

A atividade de atingir estruturação que permita a obtenção da velocidade ideal ou pelo menos a maior possível dentro da infraestrutura toma conta das preocupações de pesquisadores e analistas de dados. Essa velocidade deve inicialmente ser ativada para melhoria dos trabalhos de estruturação dessas informações. Com relação aos acessos externos (usuários finais), maiores velocidades podem interferir de forma positiva na avaliação da usabilidade das rotinas desenvolvidas.

3.2 Volatilidade no *Big Data*

Quando o tratamento da volatilidade, ou durabilidade dos dados, que nesse contexto é o processo pelo qual a pertinência ou importância da informação é medida, sugerir a eliminação de documentos gerados no dia a dia da empresa, muitas das considerações aqui colocadas podem não representar uma prática adequada, principalmente quando se leva em conta questões de preservação digital. Esta é uma ressalva necessária, já que transmitir conhecimentos sobre a gestão eletrônica de documentos (GED) não está posta no escopo desse material.

Assinalamos diversas vezes a importância de ter dados válidos, seguros e recuperáveis para que os usuários finais possam atender às suas necessidades de informações estruturadas, que lhes permitirá desenvolver de forma mais facilitada e eficaz suas atribuições. A “roda do tempo” não para e, com ela, aumenta de forma exponencial o volume de dados captado.

Apesar do barateamento acelerado do *byte* armazenado, o registro de novas informações pode superar esse aspecto e ter um custo adicionado. No entanto, o que importa está mais diretamente ligado à degradação da velocidade de acesso.

A movimentação de dados, com a criação de novas bases de dados, por exemplo, para guardar apenas o tempo de um ano, transferindo os registros “eliminados” para outros dispositivos de armazenamento, é uma das saídas possíveis. Essa consideração pode restringir o acesso às informações



importantes ou aumentar o tempo de acesso, gasto com a varredura dos arquivos complementares, mantidos como base histórica.

Dessa maneira, os projetistas, quando analisam questões de implantar a estrutura mais eficaz o possível, iniciam um jogo de “toma lá e dá cá”: maior armazenamento *versus* maior abrangência de dados *versus* maior velocidade de recuperação *versus* custo financeiro. Estes parâmetros, colocados em evidência, buscam a estrutura de melhor encaixe, satisfazendo condições ótimas de atendimento às necessidades dos usuários finais dos sistemas de gerenciamento de informação.

A computação em nuvem surge como uma solução para diminuição de custos com suporte para o estabelecimento de uma estrutura que suporte um elevado nível de permanência dos dados, em seu estado de armazenamento natural. Entretanto, nada tem a ver com questões de avaliação da volatilidade possível, a menos que esta seja uma cláusula dos “draconianos” contratados pela SLA – Service Level Agreement⁴. Existem alguns fatores a serem considerados com relação ao tratamento de análise quando da tomada de decisões importantes sobre como deve ficar a estrutura:

- estabelecer um percentual que, quando superado, retira das grandes bases de dados aqueles considerados de menor importância (cuidar com aspectos relativos a fatores legais necessários para atender aos processos de gestão eletrônica de documentos (GED));
- verificar a necessidade de a informação estar disponível *just-in-time*⁵ e *on-demand*⁶;
- verificar regras legais provenientes do Estado no que diz respeito à preservação digital;
- analisar se há dados que não mais têm valor e rotinas para identificar aqueles que atingem tal condição.

Com os dados obtidos, a verificação de questões de volatilidade pode ser desenvolvida pelos colaboradores ou consultores externos, com base no

⁴ Traduzindo, significa “Acordo de Nível de Serviço”. Esse é um acordo em que empresa e cliente se comunicam com os mesmos interesses em quesitos de prestação de serviço.

⁵ Diz-se do sistema de administração da produção em que é determinado que, antes do momento ou da hora certa, nada deve ser produzido, transportado ou comprado.

⁶ Atender àquele que necessita de algo na hora e com o conteúdo escolhido por ele.



aumento do custo de infraestrutura e da quantidade de serviços que as alterações podem provocar nos sistemas.

Saiba mais

- O tema *computação em nuvem* foi citado sem um tratamento mais aprofundado. No artigo “O que é computação em nuvem?”, postado pelos colunistas de uma das maiores empresas na área (Microsoft), o leitor pode aprender um pouco mais sobre essa importante linha de estudos. Disponível em: <<https://azure.microsoft.com/pt-br/overview/what-is-cloud-computing>>.

3.3 Tema de pesquisa sobre este tema

Considere desenvolver uma pesquisa na qual estabeleça que vantagens pode trazer a computação em nuvem para o tratamento intensivo e extensivo de dados com efetivação do fenômeno *Big Data*.

TEMA 4 – *BIG DATA* – VISUALIZAÇÃO, VIRALIDADE, VALOR

4.1 Visualização no *Big Data*

O armazenamento de dados nas grandes bases de dados surge como resultado das atividades *data mining* e *data warehouse*. São criadas localidades das quais os dados são extraídos para serem estruturados de forma que cada usuário considere mais adequado de acordo com suas necessidades. Entramos nos estudos relativos ao termo “*Data Query Language*”⁷, parte integrante sistemas SGBD – Sistemas de Gerenciamento de Bases de Dados.

Não adianta nada guardar um grande volume de dados se ele não puder ser recuperado de forma rápida. A recuperação pode estar baseada em pelo menos uma palavra-chave, sendo recomendável o uso de mais palavras-chave. A combinação permite iniciar a seleção de quais dados farão parte da estruturação que o usuário necessita.

A transformação pode ocorrer nessa etapa; os dados coletados são convertidos em informações de valor, utilizadas para solução de algum problema particular de acordo com as necessidades dos usuários. Aqui se tem início à

⁷ Comandos DQL são basicamente instruções Select. As instruções Select permitem consultar o banco de dados para localizar informações em uma ou mais tabelas e retornar à consulta como um conjunto de resultados.



etapa de análise na qual profissionais estão acostumados a trabalhar com um grande volume de informações.

No tema anterior, vimos que ter dados em profusão e velocidades de acesso compatíveis com a agilidade que o mercado exige reflete o resultado de um balanceamento criterioso. Da mesma forma, recuperar esses dados exige um estudo detalhado de prioridades, aplicadas nas transações que os usuários finais vão desenvolver.

O termo “SQL – Search Query Languages” entra, então, em cena. Quando todos os acessos são especificados em espaço de tempo anterior à sua efetivação, a estrutura pode ser disponibilizada com as facilidades de acesso já determinadas e estabelecidas. Nem sempre esse fato acontece e, muitas vezes, durante o tempo de vida do sistema e seu desenvolvimento, novos caminhos de pesquisa surgem e podem determinar, de forma decisiva, a estruturação final.

4.2 Viralidade

Grande parte dos dados levantados nas atividades de busca são armazenados na grande rede, com menor ou maior grau de liberdade de acesso. As informações postadas podem permanecer desconhecidas ou causarem pouco impacto. No entanto, é possível que a informação, de forma inesperada ou como resultado de algum planejamento bem-sucedido, atinja um estado conhecido como viralidade. O termo é utilizado com o significado de identificar conteúdo para além do esperado que se torne “viral”.

Viral deriva do vocábulo “vírus”, e entende-se por “ser viral” a mesma ação que os vírus causam, ou seja, disseminar-se e entrar em qualquer ambiente sem ser convidado. O novo vocábulo e todos os seus derivados (“vírus”, “viral”, “viralizou”, e assim por diante) se estabelecem e este parece ser o caminho mais rápido para sucesso na grande rede, ainda que ele possa ser efêmero.

O termo foi transferido para o mundo do *Big Data* sem que houvesse nenhum incentivo especial para isso, e traz o mesmo significado: alguma informação que causa impacto na grande rede e que pode revelar estratégias ou planos da empresa para novas formas de negócio e criação de novos produtos e serviços.

4.3 Valor

Taurion (2013) considera, como muitos outros pesquisadores e profissionais de TI, que no fenômeno *Big Data* há um conceito de valor que é tanto maior quanto maior for a riqueza dos dados. A captura de dados ricos em valor é resultado de uma orientação dos trabalhos de coleta de dados e sua análise para saber quais as perguntas certas e que direcionam as atividades de coleta.

As atividades de coleta trazem um dado volume de informações. É no trabalho de análise desenvolvido sobre elas que está o segredo de descobrir quais dessas informações trazem algum valor (tangível ou intangível) para a empresa.

O processo deve estar ancorado em diversos pontos nos quais as perguntas corretas devem ser efetuadas. Desse valor são descontados os custos que as atividades iniciais apresentaram.

Um processo *Big Data*, para ser considerado de valor, deve se pagar, ou seja, os custos financeiros advindos dos trabalhos de coleta, armazenamento e análise devem compensar qualquer investimento que tenha sido feito. Quando a atividade envolve benefícios intangíveis, estes precisam ser avaliados de acordo com regras particulares adotados de forma particular por cada uma dos envolvidos.

Uma política orientada no sentido de valorizar as atividades de pesquisa, coleta, armazenamento e disseminação é a melhor forma de direcionar os trabalhos de modo que o resultado compilado agregue algum valor. Eles podem ser estabelecidos em nível de melhoria de serviços de atendimento aos clientes e melhorias nos produtos ou serviços que a empresa oferece ao mercado.

Saiba mais

- No vídeo “Transmissão X Viralidade”, pode fazer você compreender melhor o conceito de viralidade. Disponível em: <<https://www.youtube.com/watch?v=AtnNvf0wTp8>>.
- Amplie um pouco mais seus conhecimentos sobre viralidade por meio do artigo “Saiba o que significa ‘viral na internet’”. Disponível em: <<http://www.ebc.com.br/tecnologia/2012/11/o-que-e-viral>>.



- Conheça mais sobre a conceituação SGDB colocada no conteúdo do texto por meio do artigo “O que é um SGBD?”. Disponível em: <<https://www.oficinadanet.com.br/post/16631-o-que-e-um-sgbd>>.

4.4 Tema de pesquisa sobre este tema

Considere desenvolver uma pesquisa na qual obtenha dados para poder exemplificar, em diferentes situações comerciais, como uma informação pode se tornar viral.

TEMA 5 – *BIG DATA* – VERACIDADE, VALIDADE, VULNERABILIDADE

5.1 Veracidade

O projeto *Big Data* adotado por uma empresa deve estar voltado para obtenção de dados verídicos e que estejam de acordo como a realidade dos mercados consultados. Não é incomum perceber, em algumas lideranças, uma grande desconfiança quando são a elas apresentados dados que discordam do que a empresa tem feito para permanecer sustentável em mercados altamente competitivos.

A falta de veracidade é um obstáculo a ser superado. Se faz necessário o desenvolvimento de tarefas que realinhem os dados de acordo com o que o mercado exige. A falta de integridade impede a utilização dos dados.

Outra situação, desagradável, é manter sob controle a identificação de quem acessa os dados. A falta de boa-fé pode colocar a perder as rotinas de segurança. Os colaboradores precisam ser identificados, bem como as operações por eles desenvolvidas.

À medida que o tempo passa, principalmente em mercados voláteis e competitivos, deve existir algum processo entregue a uma equipe ou uma pessoa que está constantemente analisando, em tempo real, eventuais mudanças de situação e de efeitos.

Outra medida depende de decisões tomadas na fase inicial do desenvolvimento das pesquisas, no sentido de determinar a relevância das informações criadas por meio dos dados coletados.

5.2 Validade

A verificação de validade no *Big Data* está diretamente sob responsabilidade dos setores de auditoria com os quais a empresa conta. Na dependência do tamanho da empresa, um setor especificamente voltado para a auditoria de dados pode não existir ou existir, mas ser subordinado a um acúmulo de funções.

Essa é uma atividade que deve ser desenvolvida para dar segurança aos dados e permitir a sua adjetivação como um dado válido. A ausência desse processo de validação pode ser responsável direta pelo tratamento incorreto ou perda de dados. A inexistência da função de auditoria de dados pode ser responsabilizada diretamente pela perda de dados.

A atividade supera a forma como é efetivada a auditoria em outras etapas nos sistemas de informação. Ela é pontual e identifica o que já aconteceu e que não mais pode ser modificado, para ter subsídios de saber o que evitar no futuro. Essa é uma das diferenças fundamentais.

OS SGDB são um dos principais alvos da auditoria de dados, por ser no interior das estruturas propostas que pode acontecer uma série de irregularidades (quebra de segurança, perda de sigilo etc.). Os dados são periodicamente submetidos a uma análise de perfil, que mostra a qualidade dos sistemas.

Na continuidade a auditoria acompanha todos os processos pontuais nos quais há movimentação, alteração ou exclusão de dados. Saindo do ambiente interno, a auditoria navega por ambientes externos, principalmente aqueles que foram, de alguma forma, fontes de captação dos dados atualmente armazenados.

Elas seguem acompanhando também o mercado de inteligência de dados, que vende quantidades consideráveis de dados para empresas que não tem a atividade estabelecida. Esses dados são conhecidos como **bases externas de mercado**, que normalmente são utilizados em campanhas de *marketing*.

A auditoria *Big Data* interfere em praticamente todos os processos que envolvem manipulação de dados: liberação de crédito; controle do volume de vendas; dados pessoais informados, entre outros. O propósito é dar aos dados a maior validade possível.



Processos de migração ou trocas que acontecem no *Big Data* são uma grande oportunidade para o surgimento de irregularidades, as mais diversas, com os dados que são manipulados. A interveniência da auditoria se estende para a validação das regras de negócio que a empresa estabeleceu. Aqui, a auditoria verifica se os dados atendem às regras de negócio (principalmente aqueles adquiridos em bases externas).

A “febre” da terceirização pontua a contratação de auditoria externa, na qual pode estar um profissional altamente qualificado, cujo cabedal não tem similar na empresa. No entanto, há uma importante ressalva: é preciso tomar muito cuidado sobre quem é o terceirizado, pois existem inúmeros riscos relacionados à segurança do *Big Data*. Ameaças relacionadas à privacidade dos dados é um dos itens que mais geram preocupações. A enorme quantidade de dados e informações coletadas faz com que seja natural o aumento de riscos envolvendo a reputação e privacidade das organizações e seus colaboradores.

A empresa pode estabelecer uma dependência indesejada. Os contratos SLA – Service Level Agreement apresentam rigor, mas, mesmo assim, irregularidades podem acontecer e muitas vezes é difícil estabelecer com quem está a razão. A auditoria encontra uma linha final que trata da análise dos relatórios produzidos nos diversos serviços desenvolvidos sobre os dados. Ganha um novo *status* nos serviços de auditoria do *Big Data* a definição de documentos apropriados, a definição de métricas e dos indicadores de qualidade que serão aplicados.

Os resultados da auditoria sobre os processos nos quais interfere e quais irregularidades foram encontradas devem ser publicados e dados a conhecer por todos os participantes. Com essa proposta, a auditoria do *Big Data* se torna uma atividade obrigatória a ser criada na cultura empresarial (aspecto hoje ausente).

5.3 Vulnerabilidade

Taurion (2013) considera que evitar a vulnerabilidade dos dados armazenados como resultado de atividades de pesquisa, coleta e armazenamento é uma atividade fundamental para qualquer empresa que deseje manter a segurança, a integridade e a privacidade dos dados.

A vulnerabilidade representa falta de cuidado que se torna presente na estruturação das grandes bases de dados. As falhas nesse processo podem



tornar os dados inseguros. A consequência disso é a perda da integridade, que impede sua utilização e acesso por pessoas internas, o que quebra a privacidade que a empresa estabeleceu como indicativo.

De acordo com o site Proxima⁸, “foram criados 33 ZB de novos dados em 2018 (11 ZB = 1 trilhão de Gigabytes)”, o que torna o acesso ao volume de dados colocados à disposição mais demorado. Mais uma vez, o balanceamento deve ser colocado entre as alternativas de melhoria. A visão da comparação entre custos e benefícios está posta. Uma “negociação” é que vai definir a escolha entre maior eficiência, escolhendo a melhor solução técnica ou aquela que mais satisfaz os usuários.

Os dados colocados na internet são colocados à disposição das pessoas interessadas, sem importar a finalidade e quais propósitos escusos possam estar ocultos. O que se esperou ser mais um modismo, tão comum na área da TI, parece ter “chegado para ficar” e justifica a criação de uma rotina que garanta a empresa impedindo que falhas de vulnerabilidade afetem a segurança, a integridade e a privacidade dos dados armazenados nas grandes bases de dados que atendem ao *Big Data*.

A falseabilidade da segurança total volta “a todo vapor”. Perdas de privacidade invalidam todo o processo que, em algumas condições, podem permitir, por exemplo, a ocorrência de algum vazamento, e tornar conhecidos os seus planos.

Outra grande ameaça que pode tornar os dados inseguros é sujeitar a empresa à invasão via ataques de vírus e outros códigos mal-intencionados. A integridade depende do sucesso nas atividades de proteção, sendo mais afetada quando a segurança e privacidade não estão garantidas. O escopo do material não abrange discussões sobre o tema.

Os fatores se entrelaçam e mostram uma dependência cruzada. O resultado dos trabalhos de defesa propostos tem um objetivo principal, que a qualidade da saída de dados seja a mesma que foi observada na entrada dos dados. O sucesso depende, também de forma intensa, dos estudos de auditoria desenvolvidos em cada etapa.

A vulnerabilidade dos dados coloca a empresa em um patamar que torna difícil garantir o sucesso de outras iniciativas. As rotinas internas dos grandes

⁸ Disponível em: <<https://www.proxima.com.br/home/proxima/how-to/2020/05/27/o-volume-de-dados-como-grande-ameaca.html>>.



repositórios de dados, de forma geral, se mostram insuficientes e a garantia da segurança, da integridade e da privacidade pode se apresentar corrompida.

A existência de pessoas ou equipes trabalhando diuturnamente na observação do que a empresa faz na rede e a que ameaças ela pode estar sujeita é uma proposta sem a qual a funcionalidade do ambiente *Big Data* pode ficar comprometida.

Saiba mais

- Acesse ao vídeo “Faça Análise de Vulnerabilidades e eleve o nível de sua Cibersegurança”, sobre questões de vulnerabilidade e formas de contornar um dos principais obstáculos para que a atividade *Big Data* tenha sucesso. Disponível em: <<https://www.youtube.com/watch?v=wiXdAkjc0U0>>.
- Leia o artigo “Aprenda as diferenças entre vírus, trojans, *spywares* e outros”, de Danilo Moroso, sobre quebras de segurança. Disponível em: <<https://www.tecmundo.com.br/phishing/853-aprenda-as-diferencas-entre-virus-trojans-spywares-e-outros.htm>>.

5.4 Tema de pesquisa sobre este tema

Considere desenvolver uma pesquisa sobre a auditoria no processo *Big Data* de modo que possa montar uma lista de recomendações, citando as fontes nas quais as informações foram obtidas.

No Fórum da semana, discuta aspectos nos quais encontrou dificuldade nos temas de estudo que estão propostos nesta aula. Procure instigar seus colegas a desenvolver uma participação ativa para efetivar a aprendizagem colaborativa e cooperativa.

TROCANDO IDEIAS

Nesta aula, foram tratados aspectos relacionados aos dados captados e armazenados pelas empresas. Eles são objeto de um estudo que visa observar o nível de sensibilidade, características e pontos de ancoragem em que são tratados segurança de informações.

Com relação à captação e armazenamento, houve um primeiro contato com rotinas de varredura e armazenamento (*data mining*). Com relação às características dos dados, foram tratados aspectos diversificados em



envolveram o estudo de volume, variedade, velocidade, volatilidade, visualização, viralidade, valor, veracidade, validade e vulnerabilidade.

É o cuidado com esses parâmetros que protege arquivos que contêm informações estratégicas, e que permite considerar que as tabelas reunidas em uma base de dados são íntegras. Cada um dos termos foi trabalhado de forma intensiva, tendo sido deixado para o final o estudo das questões de vulnerabilidade.

O tratamento desses temas é de importância estratégica para a empresa. Muitas pessoas acreditam que acidentes e perdas somente acontecem com outras empresas, e soluções protetivas encontram o “cadeado quebrado” e o acesso liberado a pessoas não autorizadas. Nesse caso, as empresas ficam sujeitas a um processo de IC, com a concorrência tendo sucesso com as informações estratégicas. Novidades podem ser divulgadas, retirando o interesse e impacto no mercado.

Essa vulnerabilidade pode também ocorrer via “ataques” internos e externos. Os ataques internos partem dos próprios colaboradores e exigem que rotinas internas com controle de acesso sejam desenvolvidas. Os ataques externos se mostram perigosos à medida que, além de acessar informações importantes, podem destruir a estrutura de dados ou a maculá-la de alguma forma. Mostramos alguns indicativos sobre como tratar esse assunto.

NA PRÁTICA

Imagine que você é o responsável pelo desenvolvimento de um guia sobre os principais cuidados a serem tomados com relação à estrutura de dados da empresa. Considere analisar separadamente questões referentes ao cuidado com os usuários internos e, no mesmo diapasão, cuidados com invasões de vírus, trojan, *rootkits* e outras ameaças. Busque métricas sugeridas por grandes fornecedores de programas, que deveriam ser defensores e que acabaram eles mesmos sendo atacados.

Dirija sua pesquisa no sentido de captar recomendações provenientes de argumentos de autoridade no tema ou na divulgação de portfólios das empresas concorrentes. Seu referencial está na internet e nas referências que lhe foram oferecidas durante o desenvolvimento do tema.

Fizemos uma visão panorâmica, sem aprofundamento maior, das características e problemas com questões de segurança dos dados armazenados pelas empresas. Antes de avançar na disciplina, é importante alertar para a importância de lançar um olhar para o futuro próximo, no qual diferentes mudanças vão atingir um grande número de ferramentas tecnológicas, alterando, como consequência, comportamentos, atitudes.

Uma primeira visão aponta para integração entre as tecnologias *Big Data* e computação em nuvem. Há uma tendência de aumento do número de empresas que têm, em seus planos, a migração total de seus dados.

A função analista de dados surge como uma das mais bem pagas no mercado da TI, profissionais com competências e habilidades em atividades de análise de grandes volumes de dados são caçados no mercado e os salários oferecidos fogem da realidade atual.

Para conhecimento do profissional da área de TI e de pessoas interessadas em ter uma formação voltada a essa área, há uma caminhada que pode ser seguida. Acompanhe na lista a seguir o que deverá ser objeto de estudo mais detalhado.

- Melhoria na preparação dos dados, antecedendo sua união para fornecer informações estruturadas para os interessados.
- Governança dos dados, que é outra consequência do crescimento do volume da oferta na grande rede.
- Análise, mapeamento e eliminação de falhas que foram observadas (utilizando técnicas preconizadas nas obras referentes de RBC – Raciocínio Baseado em Casos) e a análise de alternativas.
- Associação intensiva com a computação em nuvem, inteligência artificial e tecnologias exponenciais.
- Integração do SQL ao *Hadoop*.
- Evolução da área de análise com novas formas de desenvolvimento de análises preditivas.

As áreas supracitadas são já existentes e têm o seu grupo de melhores técnicas e práticas que devem ser aprimoradas.



REFERÊNCIAS

BERTALANFY, L. **Teoria geral dos sistemas**: fundamentos, desenvolvimento e aplicações. 8. ed. Petrópolis: Vozes, 2014.

GOMES, E.; BRAGA, F. **Inteligência competitiva em tempos de *Big Data***. Rio de Janeiro: Alta Books, 2017.

TAURION, C. ***Big Data***. São Paulo: Brasport, 2013.