



BIG DATA

AULA 2



Prof. Armando Kolbe Júnior

CONVERSA INICIAL

A manutenção da simplicidade, muitas vezes, não é obtida devido à complexidade inerente à intervenção de características técnicas. Este é o caso desta aula, na qual os termos tratados nela são voltados para características técnicas.

O próximo passo na caminhada que levará você à aquisição de novos conhecimentos se inicia com a análise do processamento em tempo real das transações efetuadas para a recuperação de dados. O percurso segue com a apresentação da integração entre o *Big Data* e o processamento em *streaming* (tal como se estabelece no P2P – *Peer To Peer*).¹

A integração entre o *Big Data* e a computação em nuvem (da qual já falamos um pouco) tem um tratamento detalhado, considerando que centenas de empresas estão migrando para a utilização dessa tecnologia. Ela deve iniciar um processo de aceleração e melhoria com o consequente aumento do capital envolvido.

Vamos também nos ater a formas sobre como trabalhar com a área de ferramentas para análise de dados. Vimos que essa é uma nova profissão que surgiu como razão direta do crescimento do volume de dados processados pelas empresas, em meio aos quais é possível encontrar *fakes*² e lixo eletrônico. Eles devem ser eliminados como forma de garantir a segurança do que está armazenado e proporcionar a construção de informações estruturadas que são utilizadas nos processos que envolvem a tomada de decisões. É uma das atividades mais importantes desenvolvidas sobre o elevado número de dados que podem ser coletados pela empresa.

Esta aula se encerra com o estudo das ferramentas para visualização de dados que representam a disseminação do conhecimento, principal razão para o uso da tecnologia *Big Data* com diferentes propósitos e aplicada a um conjunto

¹ Em uma rede P2P, os *peers* são sistemas de computador conectados entre si pela internet. Os arquivos podem ser compartilhados diretamente entre sistemas na rede sem a necessidade de um servidor central. Em outras palavras, cada computador em uma rede P2P se torna um servidor de arquivos e também um cliente. Traduzido pelo autor. Disponível em: <<https://techterms.com/definition/p2p>>. Acesso em: 30 set. 2019.

² Pode ser uma pessoa, um objeto ou qualquer ato que não seja autêntico. Com as redes sociais, o termo passou a ser muito utilizado para designar uma conta na internet ou o perfil em uma rede social de alguém que pretende ocultar a verdadeira identidade. Disponível em: <<https://www.significados.com.br/fake/>>. Acesso em: 30 set. 2019.



de dados filtrados que podem ser acessados preferencialmente com a oferta de diferentes ferramentas.

CONTEXTUALIZANDO

É importante saber mais sobre o contexto no qual são efetivadas as propostas *Big Data*. Em uma primeira visão dos termos tratados, é possível perceber que sua união com as Tecnologias da Informação e Comunicação (TIC) aumenta a cada dia.

Outro aspecto importante é a transferência do *Big Data* para o ambiente em rede, com uma integração total com a computação em nuvem. É talvez o principal motivador que direciona as linhas de pesquisa atuais sobre o tema.

O contexto também aponta para a necessidade de que os seus usuários tenham um bom nível de expertise sobre como trabalhar com as tecnologias, ainda que muitas das informações já cheguem estruturadas e com elevado volume de validação. Aqui, os usuários devem ser previamente preparados, sob pena de não acompanhar a parte inicial do *Big Data*.

É preciso buscar dados pesquisados via varredura em endereços de interesse na grande rede e nos arquivos dos sistemas de informação gerencial (*data query* e *data analysis*), determinando o que pode ser copiado e quais filtros devem ser utilizados. O processo segue para uma nova fase de análise que é desenvolvida antes de estruturar as informações de acordo com as necessidades dos usuários.

Com os dados captados, o trabalho volta para um processo de análise interna durante a qual os dados são transformados em informações estruturadas. São criadas as grandes bases de dados que compõem os repositórios de dados. Os dados originalmente captados podem, mesmo não sendo um conceito diretamente relacionado, ser guardados em forma de histórico, se valendo de um *data warehouse* (DW), como garantia da possibilidade de alguma reconstrução diferente, tomada a partir dos mesmos dados.

Figura 1 – Processamento em tempo real



Crédito: a-image/Shutterstock.

1.1 A TRANSFORMAÇÃO

A tecnologia *Big Data* surgiu como resultado de um estudo voltado para a melhoria das condições de armazenamento de grandes volumes de dados. O fator economia de recursos foi decisivo para a sua evolução até os dias atuais. Esta evolução nos trouxe a uma nova proposta de se tornar a tecnologia de armazenamento e recuperação, com a intervenção da função de análise dos dados (*data analysis*).

Na atualidade, a maioria das transações nos ambientes *Big Data* permitem que os usuários recebam as informações que desejam em tempo real. Essa realidade dependeu e muito da evolução tecnológica e de um balanceamento efetuado nas estruturas para que tal atividade pudesse ser efetivada com alto desempenho.

Um olhar para um passado recente mostra uma rápida evolução do *Big Data*. Ela provocou e ainda provoca mudanças significativas nos procedimentos desenvolvidos na área, como ser responsável por novas configurações nos



trabalhos da TI. Hoje, com o advento da *Internet of Things* (IoT),³ a realidade da recuperação de dados em tempo real deve evoluir de maneira acelerada.

A área *Business Intelligence* (BI)⁴ é chamada a intervir e o faz no sentido de orientar, de forma correta, a migração das aplicações existentes, com o foco centrado no suporte para oferta e recuperação de dados em tempo real. Esse panorama se estabelece como uma das peculiaridades da tecnologia *Big Data* nas empresas de todos os portes, considerando que, para as pequenas empresas, grandes consórcios oferecem soluções prontas a um custo menor do que aquele dispendido com a criação e a manutenção de uma estrutura interna.

1.2 O SIGNIFICADO DO PROCESSAMENTO EM TEMPO REAL

Taurion (2013) considera que a movimentação dos mercados e a migração de quase todas as empresas para a grande rede foram os fatores que apresentaram a necessidade do processamento e atendimento de necessidades dos usuários em tempo real. Essa é uma forma de eliminar a latência que podem apresentar os sistemas de informações gerenciais, o que também acontece na transferência de pacotes de dados para caminhar entre dois pontos.

O mercado se transforma e o fator aumento da velocidade nas respostas às transações efetuadas contra as bases de dados deve se apresentar com agilidade para que seja possível superar o que a concorrência está fazendo. Para além de uma situação desejável, se torna imperativo a melhoria nos tempos de resposta, o que direciona para o processamento em tempo real.

A disponibilidade dos dados *just in time* e a cobrança dos serviços na forma *on demand*⁵ são características dos ambientes onde se recomenda o uso de estruturas que permitam respostas em tempo real. O fluxo de dados deve ser contínuo, e qualquer modificação em um ponto da grande rede deve ser

³ A *Internet das Coisas* (IoT) é um termo criado por Kevin Ashton, um pioneiro tecnológico britânico, que concebeu um sistema de sensores onipresentes conectando o mundo físico à Internet enquanto trabalhava em identificação por rádio frequência (RFID). Disponível em: <<https://aws.amazon.com/pt/iot/what-is-the-internet-of-things/>>. Acesso em: 30 set. 2019.

⁴ O termo *Business Intelligence* (BI), “inteligência de negócios”, refere-se ao processo de coleta, organização, análise, compartilhamento e monitoramento de informações que oferecem suporte à gestão de negócios. Disponível em: <<https://www.oficinadanet.com.br/post/13153-o-que-e-business-intelligence>>. Acesso em: 30 set. 2019.

⁵ *On Demand* é basicamente ter a disponibilidade de assistir aos programas que você mais gosta na hora que você quiser. Tudo é possível graças à tecnologia a cabo e um superservidor local, que faz o streaming (transmite os programas sem precisar baixá-los ou armazená-los) das imagens. Disponível em: <<https://www.gdvirtual.com.br/glossario/o-que-e-video-on-demand/>>. Acesso em 08 abr. 2024.



percebido por todos os demais pontos no momento em que a mudança ocorre, com diminuição do tempo de latência.

O acesso imediato ganha destaque e surge como principal parâmetro para determinação da melhor estruturação dos dados para que seja atendido. Muitas vezes se consegue uma aproximação maior, mas não imediata, o que leva ao surgimento dos dados fornecidos em *tempo quase real*. Aqui, a latência diminui ao ponto de o usuário não perceber esta situação.

De forma consequente, o processamento ganha novo contorno. Tudo é processado em tempo real (ou quase real). É imperativo principalmente ter o controle e a resposta imediata para detecção e defesa contra ameaças. O processamento em tempo real se mostra como o caminho mais acertado para as empresas que estão estabelecidas em mercados altamente competitivos.

Vídeo

Confirme algumas das colocações deste tópico assistindo ao vídeo sobre processamento em tempo real:

Processamento de dados em tempo real com Cloud Dataflow - Fernando Ultremare. **InfoQ Brasil**, 2 de março de 2018. Disponível em: <<https://youtu.be/ZMGIvjY96Mw>>. Acesso em: 30 set. 2019.

Saiba mais

Leia este artigo que traz boas explicações sobre o processamento em tempo real no *Big Data*:

<<https://awari.com.br/big-data-conceitos-e-aplicacoes-em-tempo-real/>>. Acesso em 08 abr. 2024.

Leia o texto a seguir para aprender alguns conhecimentos mínimos sobre o tema:

Processamento em tempo real. **Microsoft Azure**, 11 de janeiro de 2018. Disponível em: <<https://docs.microsoft.com/pt-br/azure/architecture/data-guide/big-data/real-time-processing>>. Acesso em: 30 set. 2019.


1.3 TEMA DE PESQUISA SOBRE ESTE TÓPICO

Considere desenvolver uma pesquisa que lhe permita avaliar a necessidade de utilizar a perspectiva de processamento em tempo real nos arquivos de uma empresa com foco em informação disponível *just in time* e *on demand*.

TEMA 2 – BIG DATA: PROCESSAMENTO EM STREAMING

2.1 O QUE É STREAMING

Figura 2 – Streaming



Crédito: Studio888/Shutterstock.

As pessoas estão cada vez mais conectadas, utilizando como meio de suporte a internet. Esta forma de transmissão caracterizou mudanças significativas no mercado da música e, atualmente, com redes de alta velocidade, para a obtenção de filmes antes mesmo de eles serem retirados do circuito. O armazenamento de dados aumenta em progressão geométrica.

Na atualidade, as pessoas ainda conseguem acompanhar e absorver informações diversas de forma cada vez mais acelerada. A transmissão entre dois pontos se amplia, e temos o surgimento de diversas máquinas, consideradas como nós de uma rede, trocando mensagens, informações e dados de forma cada vez mais intensa.

As atividades de troca de informações tendem a aumentar de forma significativa em relação a volume e utilização. O desafio está em coletar, armazenar e analisar esse grande volume de dados com o propósito de aumentar a velocidade dessas trocas.

2.2 A TECNOLOGIA *STREAMING*

Figura 3 – Tecnologia *streaming*



Crédito: nep0/Shutterstock.

Quando a troca intensiva e extensiva se efetua na grande rede, ela recebe a nomenclatura *streaming de dados*. Na outra ponta, os dados são armazenados e também recebem atenção especial, ficando disponíveis para diferentes tipos de interação.

O *streaming* de dados utiliza tecnologia de ponta, e seu estudo mais aprofundado é tarefa das pessoas responsáveis pelos setores de TI. Mas, devido ao *Big Data* ainda estar em evolução, seu significado e manuseio ainda encontra um mercado carente de profissionais capacitados.

Os sistemas *Big Data* devem apresentar agilidade suficiente para não ser um elemento desestimulador. São sistemas que devem ter alta capacidade de adaptação às mudanças que ocorrem e se disseminam pelos nós da grande rede.



Outro aspecto que deve ser levado em consideração diz respeito à necessidade de mudar a forma de desenvolvimento de sistemas devido a uma forma de armazenamento e manutenção dos dados totalmente diferenciada. A necessidade de fluxo contínuo exige, em contrapartida, estruturas de dados diferenciadas, alta cardinalidade⁶ e o desenvolvimento de um processo de formação permanente e continuado para que os profissionais envolvidos estejam preparados para as constantes alterações que ocorrem no mercado.

Dessa forma, o que é denominado *streaming* está diretamente relacionado com o *Big Data* com transições desenvolvidas em fluxo contínuo. Existem diversas fontes para efetivar o *streaming* de dados: monitoramento de operações; *web analytics*;⁷ *mobile* desenvolvido nos celulares inteligentes; realidade aumentada; realidade virtual, entre outras fontes.

O que foi visto até agora já atua como uma definição. Para aqueles mais curiosos, é possível definir a tecnologia *streaming* como sendo uma forma de transmissão de textos digitais, áudio e vídeo que é transmitida tendo a internet como base de apoio. A evolução do *Big Data* pode ser totalmente creditada ao aumento da velocidade das transmissões facilitadas e a uma nova estruturação nas formas de armazenamento.

Um dos exemplos mais citados é o Netflix, que surgiu e, na sua esteira, derrubou outras empresas, acabando com antigas profissões, trazendo novas formas de distribuição de vídeo e atuando na modalidade *streaming*. Na plataforma Netflix, um vídeo é acessado e é solicitada sua liberação em tempo real. Como uma ideia inovadora, ela enfrentou grandes empresas que não aceitavam essa nova tecnologia e permaneceram em seu estágio, sendo aos poucos superadas.

Há uma perspectiva que com as redes 4G e 4,5G, o trabalho com fluxo de dados deva evoluir de forma significativa. Novos sistemas desenvolvidos de

⁶ É o número máximo e mínimo de ocorrências de uma entidade que estão associadas às ocorrências de outra entidade que participa do relacionamento. Ou seja, a *cardinalidade* é importante para ajudar a definir o relacionamento, pois ela define o número de ocorrências em um relacionamento. Disponível em: <<https://sites.google.com/site/uniplibancodedados1/aulas/aula-6---cardinalidade-no-relacionamento>>. Acesso em: 30 set. 2019.

⁷ *Web analytics* é a análise de dados quantitativos e qualitativos sobre a experiência dos usuários no site. São dados analisados para uma melhora constante do site a fim de atingir resultados. Disponível em: <<https://metricasboss.com.br/o-que-e-web-analytics.html>>. Acesso em: 30 set. 2019.



acordo com novos cânones das linguagens de programação e formas de análise de sistema deverão atender com o mais alto tempo de resposta possível.

Vídeo

Assista a um vídeo que pode facilitar a compreensão do termo *streaming*:

O que é Streaming? Como Funciona? Saiba mais! - Zoeweb Explica #2. **Zoeweb**, 22 de abril de 2016. Disponível em: <<https://youtu.be/QI7h-uen9U8>>. Acesso em: 30 set. 2019.

Saiba mais

Acesse este conteúdo com orientações sobre o *Big Data*:

TAMEIRÃO, N. Streaming de vídeo: o que é, vantagens e como ganhar dinheiro. **Sambatech**, 12 de julho de 2019. Disponível em: <<https://sambatech.com/blog/insights/streaming-de-video/>>. Acesso em: 30 set. 2019.

Leia este artigo e aprenda um pouco mais sobre a Netflix:

MEYER, M. A história da Netflix. **Oficina da Net**, 28 de agosto de 2017. Disponível em: <<https://www.oficinadanet.com.br/post/15898-a-historia-da-netflix>>. Acesso em: 30 set. 2019.

2.3 TEMA DE PESQUISA SOBRE ESTE TÓPICO

Considere desenvolver uma pesquisa na qual você recolha dados para montar um texto que fale de forma mais detalhada o contexto de empresas que perderam seu lugar no mercado como consequência da manutenção de paradigmas já superados.

TEMA 3 – BIG DATA: COMPUTAÇÃO EM NUVEM

3.1 A UNIÃO DE TECNOLOGIAS

Em primeiro lugar é importante destacar que tanto o *Big Data* como a computação em nuvem são tecnologias que atuam de forma independente. Ainda assim, quando unidas, é possível perceber que elas acabam por criar uma interdependência de acordo com a demanda.



A computação em nuvem é responsável pelos dados que estão armazenados e oferta um sem número de tecnologias de suporte para que o usuário possa atender suas necessidades de informação. O modelo é escalável e pode aumentar ou diminuir.

O *Big Data* e a computação em nuvem oferecem os mais variados produtos e serviços, relacionados pela proposta do uso de uma lógica diferenciada, denominada *desmaterialização*. As duas tecnologias são então utilizadas de forma a permitir que os usuários possam usufruir das vantagens dessa união. Há um grande número de pessoas oferecendo diversas soluções sobre a interdependência com mais ou menos qualidade, principalmente se levarmos em conta que analisar *Big Data* é algo bem desafiador, e essa tecnologia acaba fugindo da análise tradicional, necessitando de uma nova compreensão e maneira de lidar com os dados cada vez mais variados e volumosos.

3.2 A INTEGRAÇÃO

Considerada como a estrada do futuro, a internet contém praticamente todo o conhecimento gerado pela humanidade.⁸ Essa pode ser considerada uma das principais razões pelas quais as empresas querem migrar para a combinação *Big Data* e computação em nuvem.

Os setores de marketing, relacionamento com os clientes, vendas, dentre outros, podem estar imersos em água obscuras, com informações altamente voláteis. Ainda assim, de acordo com métricas para mensurar resultados, podem permitir algum desvio da caminhada. O ambiente no qual *Big Data* e computação em nuvens atuam e a flexibilidade desejada podem ser finalmente obtidos, eliminando uma série de passos, todos eles com os seus custos individuais.

É a hora de mandar as equipes para o *front* e liberar o acesso a todas as facilidades colocadas para as pessoas em um ambiente de *Big Data* e computação em nuvem. Essa é uma das primeiras razões que são utilizadas para a efetivação das transações que a empresa costuma apresentar em seu dia a dia.

A computação em nuvem é a responsável pelos dados armazenados e consiste na oferta de um serviço de computação na rede, aumentando a velocidade, o que vai ao encontro das características do ambiente *Big Data*.

⁸ Informações estão colocadas na grande rede, e os acessos aumentam com um aceleramento inesperado.



Existem outras razões para que o serviço não seja contratado. Compensa o fato de aliviar os provedores internos, liberando grande espaço com a eficiência na rotina de coleta, gerenciando melhor o uso dos dados, tentando garantir que a organização seja mais cada vez mais competitiva e eficaz.

De forma geral, após um balanceamento, a expectativa do mercado é que a utilização do *Big Data* se unindo à computação em nuvem representa uma tendência irreversível.

Saiba mais

Acesse o *link* a seguir e aprenda um pouco mais sobre a integração *Big Data* e computação em nuvem:

SANCHEZ, O. P.; CAPPELLOZZA, A. Antecedentes da adoção da computação em nuvem: efeitos da infraestrutura, investimento e porte. **Revista de Administração Contemporânea**, v. 16, n. 5, Curitiba, set/out. 2012. Disponível em: <<http://dx.doi.org/10.1590/S1415-65552012000500002>>. Acesso em: 30 set. 2019.

Acesse o artigo a seguir para saber mais sobre a computação em nuvem: PODEROSO, C. *Big Data* e *Cloud Computing*. **Canaltech**, 16 de abril de 2014. Disponível em: <<https://canaltech.com.br/computacao-na-nuvem/Big-Data-e-Cloud-Computing/>>. Acesso em: 30 set. 2019.

3.3 TEMA DE PESQUISA SOBRE ESTE TÓPICO

Considere desenvolver uma pesquisa na qual relacione vantagens e desvantagens de infraestrutura externa para armazenamento e acesso aos dados armazenados.

TEMA 4 – *BIG DATA*: FERRAMENTAS PARA ANÁLISE DE DADOS

4.1 PLATAFORMAS

Há ferramentas disponíveis para efetivar a análise de dados em ambientes virtuais. Algumas delas desenvolvem atividades que estão próximas à invasão de dados.

As ferramentas mais conhecidas são muitas. Vamos apresentar aqui as três principais ferramentas, além de indicar algumas plataformas:



Tabela 1 – Ferramentas para análise de dados

Nome	Descrição
IMPORT.IO	O Import.io é uma plataforma que serve para extrair dados <i>open source</i>,⁹ sem precisar digitar nenhum tipo de código de acesso. Isso significa que o ambiente <i>web</i> é visto como um grande banco de dados. Essa ferramenta é utilizada da seguinte forma: os usuários precisam inserir uma URL¹⁰ e o Import.io vai, automaticamente, tentar extrair daquele <i>website</i> todos os dados que forem considerados relevantes. Além disso, é possível extrair dados de diferentes fontes simultaneamente. Os dados coletados serão armazenados na nuvem dos servidores do Import.io, podendo ser exportados nos formatos de Excel, CSV,¹¹ JSON¹² ou acessados via Interface de Programação de Aplicações (API).
APACHE HADOOP	Em se tratando de <i>Big Data</i>, sabemos que é gigantesco o volume de dados gerados, podendo chegar a inúmeros gigabytes. Por isso, é importante poder contar com uma ferramenta dedicada ao armazenamento desses dados. O Apache Hadoop é uma das principais ferramentas de <i>Big Data</i> utilizadas no mercado. Esse famoso <i>software</i> é capaz de aumentar ou diminuir o tamanho de qualquer arquivo. Tudo isso de maneira ágil. A plataforma está disponível nas versões gratuita e paga.
ORACLE DATA MINING	A mineração de dados é uma das etapas da análise de <i>Big Data</i> que consiste em “peneirar” as informações mais relevantes em meio a todo aquele volume coletado. Para ajudar nessa parte, você pode recorrer ao Oracle Data Mining. Essa ferramenta fornece poderosos algoritmos de mineração de dados que permitem aos analistas obter <i>insights</i>, fazer previsões e alavancar investimentos. Com o ODM, você pode também criar e aplicar modelos preditivos e fazer projeções sobre o comportamento do cliente, desenvolver perfis, identificar oportunidades de vendas e detectar possíveis anomalias e fraudes.
STATWING	O Statwing é uma ferramenta muito útil para análise estatística. Para utilizá-lo, basta importar uma planilha para essa plataforma, e os dados serão verificados automaticamente. Por meio do Statwing, é possível construir

⁹ *Open source* é um termo em inglês que significa “código aberto”. Isso diz respeito ao código-fonte de um *software*, que pode ser adaptado para diferentes fins. O termo foi criado pela OSI (Open Source Initiative), que o utiliza sob um ponto de vista essencialmente técnico. Disponível em: <<https://canaltech.com.br/produtos/o-que-e-open-source/>>. Acesso em: 30 set. 2019.

¹⁰ URL é o endereço de um recurso disponível em uma rede, seja a rede internet ou intranet, e significa em inglês *Uniform Resource Locator*, e em português é conhecido por “Localizador Padrão de Recursos”. Disponível em: <<https://www.significados.com.br/url/>>. Acesso em: 30 set. 2019.

¹¹ “*Comma-separated values* (ou CSV) é um formato de arquivo que armazena dados tabelados, cujo grande uso data da época dos *mainframes*. Por serem bastante simples, arquivos .csv são comuns em todas as plataformas de computador” (Inetweb, [S.d.]). Disponível em: <<https://ajuda.inetweb.com.br/kb/o-que-e-formato-csv/>>. Acesso em: 6 abr. 2022.

¹² JSON é um formato de representação de dados baseado na linguagem de programação Javascript, daí o nome *JavaScript Object Notation*, ou seja, “Notação de Objeto em Javascript”. Disponível em: <<https://dicasdeprogramacao.com.br/o-que-e-json/>>. Acesso em: 30 set. 2019.

	relações entre diferentes dados e chegar a conclusões bem fundamentadas. Além disso, você pode: • Fazer uma análise detalhada sobre conjunto de dados; • Comparar e descrever os dados coletados; • Gerar tabelas e gráficos automaticamente.
TABLEAU	Visualizar as informações com clareza é fundamental para quem quer investir em análises de <i>Big Data</i>. Nesse sentido, uma das principais ferramentas de <i>Big Data</i> para essa finalidade (visualização) é o Tableau. Trata-se de um <i>software</i> que permite criar mapas, gráficos variados, tabelas e outros recursos gráficos para facilitar a compreensão das informações ali colocadas. Tudo isso é criado de forma rápida e atualizado em tempo real. Estão disponíveis versões gratuitas e versões pagas com funcionalidades adicionais.
CHARTIO	O Chartio permite que você combine os diferentes dados coletados e crie relatórios diretamente no seu navegador. Os arquivos, então, poderão ser convertidos em formato PDF e enviados por e-mail. Essa ferramenta também está disponível nas versões gratuita e paga.
PENTAHO	Durante a análise de <i>Big Data</i>, é interessante tentar integrar as informações das diferentes plataformas e <i>softwares</i> utilizados. O Pentaho é um exemplo de ferramenta que permite essa integração. Com o Pentaho, é possível conectar o Tableau (item 5) com as redes sociais da sua empresa e, a partir disso, ser mais eficiente no uso dessas informações. O Pentaho é gratuito no primeiro mês.
Pesquisas automatizadas	Contar com todas essas ferramentas ajuda a filtrar, selecionar e visualizar dados. Mas, muitas vezes, é necessário fazer pesquisas específicas para responder perguntas que ficaram ainda sem resposta clara para as peculiaridades do seu negócio. Nesse sentido, as pesquisas são uma importante ferramenta de coleta de dados. Elas ajudam você, por exemplo, a conhecer melhor o seu público e a entender melhor o mercado e o contexto em que a sua empresa está inserida. Com a ajuda da tecnologia, essa tarefa fica mais fácil. A MindMiners desenvolveu uma plataforma de pesquisas automatizadas para que você possa elaborar questionários e obter dados confiáveis, que servirão como um guia para as suas estratégias de negócio. Com essa plataforma, é possível: • Construir questionários personalizados e com diferentes filtros de análise; • Mapear a opinião e a percepção de clientes e fornecedores; • Estabelecer prioridades; • Acompanhar a pesquisa em tempo real; • Exportar relatórios automaticamente. Além das pesquisas, você pode também recorrer ao Miners Monitor. Trata-se de um estudo que compara os índices de satisfação dos clientes de marcas que atuam no mesmo segmento. Assim, você passa a ter acesso a dados que te darão um parâmetro maior sobre esse indicador.

Fonte: Adaptada de Abel, 2018.



Vídeo

Assista ao vídeo a seguir para se aprofundar no assunto:

Curso de Big Data - Aula 2 - Principais Ferramentas (Hadoop, HBase e Spark).

Curso de Big Data - Ricardo Paiva, 29 de março de 2016. Disponível em: <<https://youtu.be/CjRkEywm1go>>. Acesso em: 30 set. 2019.

Saiba mais

Acesse o artigo que pode ser encontrado em:

KLEIN, G. H.; GUIDI NETO, P.; TEZZA, R. Big Data e mídias sociais: monitoramento das redes como ferramenta de gestão. **Saúde e Sociedade**, v. 26, n. 1, p. 208-217, 2017. Disponível em: <<http://dx.doi.org/10.1590/s0104-12902017164943>>. Acesso em: 30 set. 2019.

Conheça um pouco mais sobre o monitoramento das redes sociais. Acesse o dicionário de significados e aprenda um pouco mais sobre as atividades de *data warehouse*.

Significado de data warehouse. Significados. Disponível em:

< <https://aws.amazon.com/pt/what-is/data-warehouse>>. Acesso em: 30 set. 2019.

4.2 TEMA DE PESQUISA SOBRE ESTE TÓPICO

Considere desenvolver uma pesquisa na qual obtenha dados para fazer um comparativo entre as diferentes ferramentas da *web*. Escolha na lista de oito que foram apresentadas, as duas que mais despertaram seu interesse.

TEMA 5 – BIG DATA: FERRAMENTAS PARA VISUALIZAÇÃO DE DADOS

5.1 O QUE É

Você pesquisou dados, escolheu aqueles de seu interesse, providenciou o armazenamento e a preservação dos dados com segurança, efetuou as transformações necessárias para criar as informações que os usuários necessitam. Após essas atividades, o que deve ser feito? Resta desenvolver as leituras das informações necessárias para que diversos setores possam apoiar, com base nas informações armazenadas. As informações precisam ser visualizadas de acordo com a motivação que orientou as fases iniciais.



A visualização de dados não é um processo exclusivo do *Big Data* e é tratado, em muitos dos materiais que podem ser encontrados na grande rede e em livros sobre outros assuntos, de forma independente. A sua associação com o fenômeno *Big Data* traz benefícios e aumenta a competitividade da empresa, quando tal associação é desenvolvida sobre grande número de informações em tempo real e de forma incremental, quando as ações são pertinentes (dados se referem ao mesmo assunto).

Taurion (2013) considera que as tecnologias de visualização e animação de dados devem ser privilegiadas na próxima década e vão tornar mais eficaz a busca de informações presentes na grande rede. O autor considera que é a partir de visualizações e animações que os usuários poderão aumentar a sua independência e que, com tais movimentações, a tomada de decisões será mais facilmente atingida.

O surgimento de uma área de estudos independente, a partir do volume crescente de dados, traz a necessidade de modificação nas ferramentas de visualização de dados. Apesar de não representar uma novidade, ela ainda não apresenta uma demanda elevada, ou seja, ainda não temos necessidades de alterações no modelo atual de visualização de dados.

No princípio da utilização de grandes SGBD, as rotinas de visualização utilizavam chaves de pesquisa (primárias¹³ e secundárias¹⁴). De forma abrangente, essa atividade era denominada (*query languages*,¹⁵ *query by example*, dentre outras designações particulares). A evolução tecnológica e o aumento da velocidade de acesso, a diminuição do custo de armazenamento e a associação com a plataforma de computação em nuvem levaram a associações diferenciadas. Elas auxiliam as pessoas que trabalham com

¹³ Este tipo de chave refere-se aos conjuntos de um ou mais campos, cujos valores, considerando a combinação de valores de todos os campos da tupla (registro), nunca se repetem e que podem ser usados como um índice para os demais campos da tabela do banco de dados. Em chaves primárias, não pode haver valores nulos nem repetição de tuplas. Disponível em: <<https://www.diegomacedo.com.br/entendendo-as-chaves-dos-bancos-de-dados/>>. Acesso em: 30 set. 2019.

¹⁴ Este outro tipo de chave é utilizado para criar os relacionamentos entre as tabelas. Imagine que você queira cadastrar vários produtos que sejam de uma determinada categoria. Disponível em: <<https://www.diegomacedo.com.br/entendendo-as-chaves-dos-bancos-de-dados/>>. Acesso em: 30 set. 2019.

¹⁵ Criada principalmente para criar, acessar e modificar dados de um sistema de gerenciamento de banco de dados (DBMS). Geralmente, a QL exige que os usuários insiram um comando estruturado semelhante e próximo à construção de consulta em inglês. Por exemplo, a consulta SQL: SELECT * FROM. Disponível em: <<https://www.techopedia.com/definition/3948/query-language>>. Acesso em: 30 set. 2019.

grandes volumes de informações a adotar uma rotina geral de utilização das informações que estão armazenadas, mantendo, porém, o mesmo propósito e objetivo. A busca de padrões é colocada em destaque.

Vamos enumerar na tabela seguinte o nome das técnicas mais utilizadas com breves descrições sobre elas:

Tabela 2 – Técnicas

Técnica	Descrição
<i>Tag clouds</i> (nuvem de palavras ou nuvem de etiquetas)	Exibição de itens presentes na grande rede e que são colocados em evidência por sua popularidade ou pelo número de itens com os quais estão relacionados. Ao utilizar uma <i>tag cloud</i> , o usuário é levado a acessar uma coleção de itens associados com essa <i>tag</i> . É possível assinalar como rotinas mais comuns para geração de <i>tags</i> os relacionados a seguir. Cada um dos itens está associado a um link no qual pode ser visualizado. Uma pesquisa sobre o tema no Goggle nos permite acessar diferentes ferramentas de <i>software</i> relacionados com o tema.
	Figura 4 – Exemplo de <i>tag cloud</i>
	Crédito: Rafal Olechowski/Shutterstock.
Softwares	Há uma diversidade de softwares que não serão tratados neste tópico, mas que fazem parte de indicadores sobre o desenvolvimento da atividade. É possível relacionar os diversos <i>softwares</i> , alguns com interfaces gráficas interessantes e com uso extensivo de soluções gráficas de visualização, semelhantes aos desenhos de produção de infográficos. Entre esses produtos, podemos relacionar os mais citados na indústria de <i>software</i> para atendimento: FusionCharts Suite XT; QlikView; Tibco Spotfire; Watson Analytics; Sisense; Tableau; Data Wrapper; Microsoft Power BI; Infogram; Plotly.

Fonte: elaborada pelo autor.

Ao acessar cada um desses produtos relacionados na segunda linha da tabela (o que você pode fazer com qualquer mecanismo de busca de sua



preferência), você irá reparar que há um ingresso no campo de estudos extenso da *Business Intelligence* (BI), uma das áreas com maior desenvolvimento na atualidade. Outro destaque de interesse é o direcionamento de todos eles para a utilização de ferramentas gráficas, consideradas como de compreensão mais facilmente captada pelos usuários finais.

Vídeo

Acesse ao vídeo demonstrativo de uma das ferramentas descritas na tabela montada sobre o assunto, o software FusionCharts Suite XT (ative as legendas para a leitura do que o orador está apontando):

Fusion Charts. **SmartBear**, 25 de julho de 2011. Disponível em: <https://youtu.be/C_7Clww6En4>. Acesso em: 30 set. 2019.

Saiba mais

Leia um artigo relacionado à visualização de dados:

NHACUONGUE, J. A.; FERNEDA, E. O campo da ciência da informação: contribuições, desafios e perspectivas. **Perspectivas em Ciência da Informação**, v. 20, n. 2, Belo Horizonte, abr/jun. 2015. Disponível em: <<http://dx.doi.org/10.1590/1981-5344/1932>>. Acesso em: 30 set. 2019.

Ainda que não tenha sido diretamente citada no texto, os dois últimos capítulos estão diretamente relacionados com a *inteligência empresarial* (tradução de *Business Intelligence*). Dessa forma, é importante que você tenha um conhecimento, um pouco mais detalhado, dessa área de intensivos estudos no campo da administração de empresas e que oferece suporte para a gestão de negócios. Assim, leia o seguinte o artigo:

SILVA, R. A. da; SILVA, F. C. A.; GOMES, C. F. S. O uso do *Business Intelligence* (BI) em sistema de apoio à tomada de decisão estratégica. **Revista GEINTEC**, São Cristovão, v. 6, n. 1, p. 2780-2798, 2016. Disponível em: <https://www.researchgate.net/publication/299571762_O_USO_DO_BUSINESS_INTELLIGENCE_BI_EM_SISTEMA_DE_APOIO_A_TOMADA_DE_DECISAO ESTRATEGICA_USING_BUSINESS_INTELLIGENCE_BI_IN_MAKING_SUPPORT_SISTMA_STRATEGIC_DECISION>. Acesso em: 30 set. 2019.

5.2 TEMA DE PESQUISA SOBRE ESTE TÓPICO

Você teve relacionados diversos softwares de trabalho. Acesse seu navegador preferido e monte um comparativo entre estes produtos, na visão de um pesquisador do assunto, com uma breve descrição de cada um deles. Você poderá escolher um dos softwares ou desenvolver esta análise para todos eles.

FÓRUM

Discuta com seus colegas de curso o que considerou relevante para aumentar seu conhecimento sobre o *Big Data* e sua integração com outras áreas, colocando também as dúvidas que teve durante os estudos. A participação será monitorada pelos professores, com intervenções para a solução de dúvidas mais comuns.

TROCANDO IDEIAS

Você teve a oportunidade de conhecer diversos aspectos relacionados com as atividades de tópicos relacionados com o *Big Data* aqui tratados de forma isolada. Eles podem estar relacionados com uma série de outros aspectos ligados ao uso da ciência informática aplicada para solução de problemas relativos, em sua maioria, aos processos de tomada de decisões.

Destaque-se que os temas adentraram quatro diferentes áreas de interesse. A primeira delas relativa ao próprio *Big Data*; a segunda relativa ao estudo da ciência da informação; a terceira relacionada com atividades de *data mining* e *data warehouse*; e a quarta que trata da importância de elevar a empresa à condição de uma empresa inteligente, que direciona todos os seus esforços no sentido de apoiar o processo de tomada de decisão em suas diversas áreas e com necessidades pontuais diferenciadas.

Muitos dos temas aqui tratados serão novamente analisados em outros pontos sob diferentes visões, mas que conduzem ao mesmo tema final: o valor da informação. O mais importante a ressaltar é que, mais uma vez, é destacado o valor do conhecimento criado com apoio em um grande número de informações. É possível observar um número cada vez maior de pessoas sem o trato informático, sendo desafiadas a adquirir conhecimentos na área sem a necessidade de se tornarem experts em variados níveis na área.

Uma das atividades mais importantes e destacadas diz respeito à importância da visualização de um grande universo de dados, captados nas atividades de *data mining* e *data warehouse*. Todo o processo de preparação é direcionado para apresentar as informações que os usuários necessitam para solucionar problemas em suas áreas e que estão, de alguma forma, diminuindo a capacidade de uma participação mais competitiva em um mercado volátil e sujeito a diferentes aspectos externos.

Para a fixação dos conteúdos, é recomendável que você tenha compreendido a importância das rotinas de recuperação do patrimônio de dados da empresa, armazenado em grandes bases de dados gerenciadas pelos Sistemas de Gerenciamento de Bases de Dados (SGDB). A partir da análise do conteúdo de seu material de estudo, monte um guia para os usuários iniciantes sobre como solicitar e utilizar a modificação dos dados pertinentes, transformados em informações valiosas para o processo de tomada de decisões.

FINALIZANDO

Você finalizou mais uma importante parcela de um conhecimento que irá permitir a participação em equipes de projeto montadas com a função de dar para a empresa uma rotina de acesso aos dados. A parte prática foi colocada em destaque devido à complexidade do tema e ao nível de conhecimento necessário para a compreensão da parte técnica.

O estudo é complexo e exige uma formação informática de base, o que geralmente não é o caso de grande parte dos usuários finais em postos de chefias intermediárias. Isto exige uma contrapartida: a formação de equipes multidisciplinares das quais um técnico informático participe para evitar que todo o ferramental utilizado para compor informações não se perca.

Quando a ausência de tal destaque é observada, fica evidente um mau aproveitamento de tudo o que a empresa investiu. Na dependência do tamanho da empresa e da não utilização da terceirização, ocorre a aquisição de um conjunto de *softwares*. Todos eles apresentam preços elevados e necessidades de formação de uma massa crítica de profissionais que absorvam os conhecimentos informáticos necessários ao bom desempenho em uma das



áreas mais importantes da empresa, disseminada entre diversos departamentos: a tomada de decisões com apoio de informações *just in time* e *on demand*.

Nos casos de terceirização dessas atividades, o custo pode aumentar e vir a ser criado um vínculo de dependência, considerando que o controle de tudo o que é estratégico para a empresa não está mais em suas mãos.



REFERÊNCIAS

ABEL. C. Análise de dados: conheça as 8 principais ferramentas de Big Data para usar nos negócios. **MindMiners**, 5 de novembro de 2018. Disponível em: <<https://mindminers.com/blog/ferramentas-de-big-data/>>. Acesso em: 30 set. 2019.

TAURION, C. **Big Data**. São Paulo: Brasport, 2013.