



MÉTODOS QUANTITATIVOS

AULA 5



Profª Aline Purcote



CONVERSA INICIAL

Anteriormente, estudamos as classificações das séries estatísticas sendo uma delas a série temporal também chamada de *histórica* ou *cronológica* onde os dados são apresentados em uma faixa de tempo. Uma série temporal é um conjunto de dados ordenados no tempo e sua análise é o processo que dá sentido aos dados, sendo uma técnica estatística utilizada na análise dos dados, na análise de tendências e previsão de acontecimentos futuros.

Sempre nos deparamos com esse tipo de série no nosso dia a dia e nas empresas, por exemplo, temperaturas diárias de uma determinada região, vendas mensais, produção anual, faturamento mensal, gráfico de controle de um processo produtivo, gastos mensais e valores de fechamento diários do Ibovespa.

Nesta etapa, vamos detalhar os principais conceitos envolvendo as séries temporais, como realizar a análise das séries além de verificar algumas aplicações.

CONTEXTUALIZANDO

As séries temporais são utilizadas em diferentes áreas. Na área de negócios podemos utilizar as séries para análise de tendências ou realizar previsão de demanda e oferta com base em dados passados. Na área de economia e finanças temos, por exemplo, o Produto Interno Bruto (*PIB*), o Índice de Preços ao Consumidor (*IPC*) e podemos utilizar para prever comportamentos e movimentações no mercado financeiro como histórico de preços de uma ação em bolsa de valores, taxas de inflação, taxas de juros, variação cambial, entre outras variáveis econômicas.

Nas ciências sociais as séries podem ser taxa de natalidade, dados de migração, aumento da população e fatores políticos. Já nas organizações podemos ter como aplicações a previsão econômica, previsão de vendas, análise orçamentária, análise do mercado de ações, projeções de rendimento e controle de processos e qualidade. Logo, as séries temporais oferecem diferentes perspectivas sobre a realidade dos negócios embasando a tomada de decisão e permitindo ações mais eficazes tornando-se uma ferramenta estratégica.

Castanheira (2011) define uma série temporal como um conjunto de valores observados em momentos distintos e sequencialmente ordenados no tempo. É um conjunto cronológico de observações. Já Souza et al. (2004) definem uma série temporal como um conjunto de observações de uma dada variável, ordenado segundo o parâmetro tempo, geralmente em intervalos equidistantes.

Segundo Sharpe, Veaux e Velleman (2011), sempre que tivermos dados registrados sequencialmente ao longo do tempo e considerarmos o tempo um importante aspecto dos dados, temos uma série temporal. A maioria das séries temporais são igualmente espaçadas em intervalos aproximadamente regulares, como mensal, trimestral e anual.

Uma série temporal é representada matematicamente como:

$$Y = f(t)$$

onde:


- Y = variável dependente em estudo;
- f = método que relaciona o valor de Y com a data de referência;
- t = data de referência.

Conforme estudamos em etapa anterior, uma série temporal é representada graficamente por um gráfico de linha onde se observa uma variável ao longo do tempo em que o tempo é representado no eixo x (eixo horizontal) e a variável em estudo é representada no eixo y (eixo vertical). De acordo com Castanheira (2011), o gráfico é um elemento importante na análise de uma série temporal, pois, com base nele, temos uma visão com detalhes do comportamento da variável em observação.

McClave, Benson e Sincich (2009) comentam que os gráficos de séries temporais revelam o movimento (tendência) e as mudanças (variações) nas variáveis que estão sendo monitoradas. Os pontos representados graficamente são conectados, geralmente, por linhas retas para tornar mais fácil a visualização das mudanças e o movimento das medições ao longo do tempo.

Exemplo 1


Nesse exemplo temos no eixo x a representação dos intervalos regulares de tempo (meses) e no eixo y a representação das vendas (unidades) em cada período.



Fonte: McClave et al., 2009.

Exemplo 2

No eixo x temos a representação dos intervalos regulares de tempo (anos) e no eixo y a representação do consumo de energia elétrica residencial no Brasil em cada ano.



Fonte: Silva, 2023.

As séries temporais podem ser utilizadas como um método quantitativo de previsão que faz uso de dados históricos. De acordo com Souza e Camargo (2004), a previsão de uma série temporal é simplesmente o estabelecimento dos



valores futuros da série. Uma previsão é uma estimativa quantitativa acerca da verossimilhança de eventos futuros, baseados na informação atual e passada. A previsão quantitativa, elaborada com o uso de métodos quantitativos, é uma projeção dos modelos para além do período que eles foram estimados.

Após obter uma série temporal podemos estar interessados em investigar o mecanismo gerador da série, fazer previsões de valores futuros, descrever o comportamento da série ou procurar periodicidades relevantes nos dados. Quando o objetivo for realizar previsões estas podem ser de curto prazo como previsão de vendas, produção ou estoque, ou de longo prazo.

TEMA 2 – COMPONENTES DAS SÉRIES TEMPORAIS


De acordo com Castanheira (2011), na análise de séries temporais são identificados os fatores que influenciam os valores da série, podendo revelar a presença dos seguintes componentes básicos:

- Tendência secular (T);
- Flutuações cíclicas (C);
- Variações sazonais (S);
- Variações aleatórias ou irregulares (I).

A tendência é um componente de longo prazo associado ao movimento da variável no tempo sendo um movimento regular e suave observada quando a série temporal seguir uma determinada direção, crescente ou decrescente, e não necessariamente linear. É um movimento de direção geral que reflete as mudanças nos dados de modo consistente e gradual podendo ser uma tendência linear, exponencial, polinomial etc. Segundo Castanheira (2011), as tendências podem estar influenciadas por fatores como crescimento populacional, taxa de desemprego, comportamento na conservação de recursos hídricos, entre outros.


De acordo com Castanheira (2011), a tendência em uma série temporal é dita secular porque sempre se refere à direção do movimento dos dados a longo prazo (no mínimo, dez anos). A avaliação da tendência é uma ferramenta que auxilia no estudo de planejamento a longo prazo, pois, baseada na análise de tendência, uma empresa pode decidir crescer, diminuir ou permanecer como está durante certo tempo.

Exemplo 1 – Tendência de decrescimento em uma série temporal



Fonte: Silva, 2023.

Exemplo 2 – Tendência de crescimento em uma série temporal




Fonte: Castanheira, 2011.

O segundo componente são as Flutuações Cíclicas definidas por Castanheira (2011) como a parte da série temporal que apresenta certo grau de regularidade nas variações ao longo do tempo, para períodos maiores que um ano. O Ciclo é o componente de médio prazo associado a variações de conjuntura econômica, com períodos de expansão e de recessão, fenômenos associados às estações do ano e à demanda de certos produtos em uma determinada estação do ano que se repetem com alguma regularidade dentro de um período maior que 1 ano.


De acordo com Souza et al. (2021), ciclos são movimentos ascendentes ou descendentes em uma linha temporal, que ocorrem de forma cíclica dentro de uma tendência. Esses ciclos são baseados, principalmente, na vida do produto e nos ciclos de reposição.

Exemplo 3



Fonte: Castanheira, 2011.

Exemplo 4



Fonte: Silva, 2023.

O terceiro componente é a sazonalidade, que é um componente de curto prazo associado a um padrão que se repete com certa periodicidade dentro de um ano. Segundo Souza et al. (2021), é um componente que é explicado com um movimento na linha temporal, que ocorre repetidamente em períodos específicos. Podemos considerar como exemplo as variações provocadas pelas épocas do ano (meses quentes ou frios, épocas de festas etc.) que afetam produtos como refrigerantes, roupas, alimentos, entre outros. Imagine uma pousada situada no litoral onde o número de hóspedes atinge valores máximos no verão e alcança valores mínimos no inverno, ou seja, dizemos que a série temporal do número de hóspedes apresenta efeitos de sazonalidade.


De acordo com Sharpe, Veaux e Velleman (2011), os componentes sazonais estão geralmente relacionados a padrões externos, eles são geralmente estáveis e previsíveis. Por exemplo, uma loja de vendas a varejo



pode prever as vendas para a próxima época de feriados com base nas informações referentes aos feriados anteriores e à tendência geral. Embora o ambiente do varejo possa mudar, eles sabem que a época dos feriados deste ano irá ser mais parecida com a mesma do ano anterior do que as vendas do último mês.

Segundo Castanheira (2011), a sazonalidade se assemelha aos fenômenos cíclicos, porém somente nos casos em que os dados são registrados a curto prazo: diariamente, semanalmente, mensalmente etc., para intervalos de tempos de no máximo um ano.


Exemplo 5



Fonte: Siqueira, 2021.

O último componente são as variações aleatórias ou irregulares que são fenômenos que não ocorrem com regularidade como, por exemplo, efeitos causados por greves, guerras, enchentes e seca. De acordo com Souza et al. (2021), a irregularidade é considerada com um ruído, um erro aleatório presente no modelo de série temporal. Tudo que não representar uma tendência, um ciclo ou uma sazonalidade é considerado um erro aleatório, ou seja, uma irregularidade.

Exemplo 6




Fonte: Silva, 2023.




Os componentes estudados não necessariamente são encontrados de forma isolada nas séries, é comum encontrar combinações em diversos tipos de dados.

Exemplo 7 – Série característica com efeitos sazonais envolvendo a venda de certo produto. Além dos efeitos sazonais, a série apresenta também tendência linear positiva:



Fonte: Souza et al., 2021.

Exemplo 8



Fonte: Análise..., 2022.

TEMA 3 – ANÁLISE DE SÉRIES TEMPORAIS

Em algumas situações a análise de séries temporais pode ser utilizada com o objetivo de realizar previsões de valores futuros e em outras a estrutura



da série ou sua relação com outras séries pode ser o principal objetivo. Castanheira (2020) comenta que analisamos uma série temporal para podermos elaborar um modelo estatístico que descreva de forma adequada a procedência da série, baseando-nos nas amostras observadas para, com base na série, podermos ou prever a evolução futura da série ou entender qual a relação existente entre os componentes do modelo. Os objetivos da realização da análise de séries temporais podem estar vinculados aos seguintes elementos:

- a. Descrição: construção de um gráfico que mostra como a série evolui no tempo, podendo indicar as propriedades da série, padrão de tendência, existência de variação sazonal, *outliers* e alterações estruturais. Podem ser obtidas medidas descritivas de suas principais características bem como a construção de histogramas e diagramas de dispersão;
- b. Explicação: considerando um conjunto de observações de duas ou mais variáveis, pode ser possível explicar o comportamento de uma em função das demais;
- c. Previsão: prever valores futuros com base em valores passados. Constitui um dos principais objetivos da análise de séries temporais;
- d. Controle: quando uma série temporal mede qualidade, o objetivo da análise pode ser de controlar o processo gerador. Por exemplo, controle estatístico de qualidade.

Para realizar a análise de séries temporais, podemos seguir alguns passos como:

- Coleta e organização dos dados: coletar dados relevantes para a análise e organizar em uma estrutura adequada como uma tabela;
- Exploração dos dados: visualizar os dados e identificar possíveis padrões ou comportamentos. Nessa etapa podemos utilizar gráficos de linha e histogramas;
- Decomposição da série temporal: a série temporal pode ser decomposta nos componentes estudados no tópico 2, permitindo entender melhor a estrutura dos dados e facilitar a modelagem;
- Escolha do modelo: a escolha do modelo para a análise de séries temporais é essencial e deve ser baseada na natureza dos dados e nos objetivos da análise;



- Estimação dos parâmetros: após escolher o modelo, é necessário estimar seus parâmetros. Esse processo pode ser realizado utilizando métodos estatístico como o método dos mínimos quadrados que estudaremos no tópico 4;
- Avaliação do modelo: após a estimação dos parâmetros, é importante avaliar a qualidade do modelo através da análise dos resíduos, testes de diagnóstico e métricas de desempenho, como o erro médio quadrático (*RMSE*) ou coeficiente de determinação (R^2);
- Previsão e interpretação dos resultados: com o modelo ajustado e validado, é possível realizar previsões futuras e interpretar os resultados obtidos utilizando para tomada de decisões, planejamento e controle de atividades.

De acordo com Sharpe, Veaux e Velleman (2011), a maioria dos métodos de análise de séries temporais usa os valores prévios de uma série para prever o(s) próximo(s). Alguns métodos descrevem o padrão geral da série e preveem que ele irá continuar, pelo menos por algum tempo. Outros métodos estimam modelos de séries temporais que identificam estruturas como tendências e flutuações sazonais nas séries e as modelam.

Segundo Souza et al. (2021), técnicas estatísticas são utilizadas para isolar os componentes sazonalidade, tendência, ciclo e irregularidade. Assim, eles podem seguir modelos aditivos ou multiplicativos. Considerando que, para qualquer período de uma série temporal, o valor da série (Y) é função dos quatro componentes que estudamos no tópico 2, podemos ter os seguintes modelos:

- Modelo aditivo:

$$Y = T + C + S + I$$

- Modelo multiplicativo:

$$Y = T \cdot C \cdot S \cdot I$$

No modelo aditivo considera-se o crescimento ou decréscimo em valores absolutos constantes. De acordo com Castanheira (2011), o modelo multiplicativo admite que os quatro componentes atuem proporcionalmente ao nível geral da série temporal. Entre os diferentes modelos de séries temporais, o modelo multiplicativo é o mais utilizado.



Segundo Souza et al. (2021), o ajuste de modelos estatísticos é extremamente utilizado em análise de séries temporais, uma vez que, sob a modelagem feita, podemos descrever matematicamente e estatisticamente as principais características geradoras do processo, o que é importante para inferências e previsões da série. Existem, de fato, diversos modelos para séries temporais, adequados de acordo com especificidades da série em análise e suas estruturas. Além disso, os modelos costumam ser dependentes de parâmetros para suas completas determinações, que são desconhecidos na prática, mas estimados por procedimentos estatísticos inferenciais.

Para realizar a análise de uma série temporal podemos utilizar o método de regressão que estudamos em etapa anterior e também o método das médias móveis conforme estudaremos no próximo tópico.

TEMA 4 – MÉTODOS DE ANÁLISE PARA SÉRIES TEMPORAIS

No tópico 2, estudamos os componentes de uma série temporal, sendo um deles a tendência. Em algumas situações isolar a tendência em uma série é interessante para identificar e usar como referência na tomada de decisão ou removê-la para analisar com mais detalhes os demais componentes da série.

A obtenção da tendência pode ser feita por meio de um modelo de regressão, médias móveis ou através de ajuste exponencial. Na regressão utilizamos o método dos mínimos quadrados que é semelhante ao usado na regressão linear simples que estudamos em etapa anterior onde a variável independente será sempre o tempo. De acordo com Castanheira (2011), o Método dos Mínimos Quadrados consiste em se obter a equação da reta ou da curva de ajustamento (ou curva de tendência) que melhor represente a tendência da série temporal.

Souza et al. (2021) comentam que a tendência linear pode ser desenvolvida com a análise de regressão linear simples, por meio da qual podemos calcular os coeficientes da reta e o coeficiente de determinação e validar o ajuste. Assim, realizam-se as previsões de acordo com essa tendência para períodos futuros.

Em etapa anterior, estudamos que uma regressão é dita linear quando o ajustamento dos dados é feito por uma função do primeiro grau tendo como representação uma reta, assim, o principal objetivo é aproximar por uma linha reta um conjunto de valores, determinando a equação de regressão linear



simples que melhor se ajuste aos dados. Logo, precisamos encontrar os coeficientes da equação da reta:

$$y = a + bx$$

onde y é chamado de variável dependente, o x é a variável independente e a e b são os coeficientes. O método utilizado para encontrar as estimativas dos coeficientes é o Método dos Mínimos Quadrados em que consiste em tomar como estimativas os valores que minimizam a soma dos quadrados dos desvios. Os valores dos coeficientes são calculados utilizando as seguintes fórmulas:

$$b = \frac{n \sum x.y - \sum x. \sum y}{n \sum x^2 - [\sum x]^2}$$
$$a = \left[\frac{\sum y}{n} \right] - b \left[\frac{\sum x}{n} \right] \quad \text{ou} \quad a = \bar{y} - b\bar{x}$$

Exemplo 1 – Considere a seguinte série temporal que representa as receitas brutas de uma determinada empresa, em bilhões de reais (R\$), e ajuste os dados utilizando o Método de Regressão Linear.

Ano	Receita
2009	18,0
2010	18,5
2011	18,9
2012	18,8
2013	19,8
2014	20,5
2015	20,1
2016	19,6
2017	21,0
2018	21,9
2019	23,1
2020	24,1
2021	28,9
2022	31,9

Para facilitar os cálculos, vamos utilizar valores codificados consecutivos de 0 a 13 para representar a variável x (ano codificado), assim:



Ano	x	Receita
2009	0	18,0
2010	1	18,5
2011	2	18,9
2012	3	18,8
2013	4	19,8
2014	5	20,5
2015	6	20,1
2016	7	19,6
2017	8	21,0
2018	9	21,9
2019	10	23,1
2020	11	24,1
2021	12	28,9
2022	13	31,9

Agora precisamos calcular os coeficientes a e b para após encontrar a equação da reta. Para o coeficiente b precisamos realizar os cálculos de $x.y$, x^2 para cada linha da tabela e encontrar os somatórios:

Ano	x	Receita	x.y	x ²
2009	0	18,0	0,0	0
2010	1	18,5	18,5	1
2011	2	18,9	37,8	4
2012	3	18,8	56,4	9
2013	4	19,8	79,2	16
2014	5	20,5	102,5	25
2015	6	20,1	120,6	36
2016	7	19,6	137,2	49
2017	8	21,0	168,0	64
2018	9	21,9	197,1	81
2019	10	23,1	231,0	100
2020	11	24,1	265,1	121
2021	12	28,9	346,8	144
2022	13	31,9	414,7	169
Total	91	305,1	2174,9	819

Para primeira e segunda linha da tabela temos:

- Primeira linha:

$$x \cdot y = 0 \cdot 18 = 0$$

$$x^2 = 0^2 = 0$$

- Segunda linha:

$$x \cdot y = 1 \cdot 18,5 = 18,5$$

$$x^2 = 1^2 = 1$$

Com os dados da tabela, aplicamos a fórmula do b considerando $n = 14$ que é a quantidade de anos apresentados na tabela:

$$b = \frac{n \sum x \cdot y - \sum x \cdot \sum y}{n \sum x^2 - [\sum x]^2}$$

$$b = \frac{14 \cdot 2174,9 - 91 \cdot 305,1}{14 \cdot 819 - (91)^2}$$

$$b = \frac{30448,60 - 27764,10}{11466 - 8281}$$

$$b = \frac{2684,50}{3185} = 0,8429$$

Com o valor de b calculamos o coeficiente a , assim:

$$a = \left[\frac{\sum y}{n} \right] - b \left[\frac{\sum x}{n} \right]$$

$$a = \left[\frac{305,1}{14} \right] - 0,8429 \left[\frac{91}{14} \right]$$

$$a = 21,79286 - 0,8429 \cdot 6,5$$

$$a = 21,79286 - 5,47885$$


$$a = 16,3140$$

Com os coeficientes encontramos a equação da reta que ajusta os dados:

$$y = a + bx$$

$$y = 16,3140 + 0,8429x$$

No seguinte gráfico é indicado a linha de tendência encontrada junto com os valores da série temporal:



Outro método que pode ser utilizado é a Média Móvel. Segundo Sharpe, Veaux e Velleman (2011), o método de suavização mais comumente usado é o método das médias móveis. Uma média móvel substitui cada valor de uma série temporal por uma média dos valores adjacentes. O número de valores que usamos para construir estas médias é chamado de comprimento da média móvel. O comprimento é uma escolha subjetiva, mas deve ser especificada quando discutimos uma média móvel.

Segundo Castanheira (2011), a média móvel de ordem k de um conjunto de números $Y_1, Y_2, Y_3, \dots, Y_n$ é a sequência de médias:

$$MM = \frac{Y_1 + Y_2 + Y_3 + \dots + Y_k}{k}$$

$$MM = \frac{Y_2 + Y_3 + Y_4 + \dots + Y_{k+1}}{k}$$

$$MM = \frac{Y_3 + Y_4 + Y_5 + \dots + Y_{k+2}}{k}$$

·
·
·

$$MM = \frac{Y_{n+1-k} + Y_{n+2-k} + Y_{n+3-k} + \dots + Y_n}{k}$$

De acordo com Castanheira (2011), o cálculo da média móvel é determinado pela média aritmética dos últimos k pontos observados e, à medida que consideramos uma nova observação, abandonamos a observação mais antiga.



Exemplo 2 – Uma empresa quer prever o faturamento para o próximo ano por médias móveis, para isso, observou os últimos 10 anos. Encontre as médias considerando ordem (comprimento) igual a 3.

Ano	Faturamento (R\$)
2013	45.163
2014	45.998
2015	46.816
2016	47.311
2017	47.758
2018	48.164
2019	48.548
2020	47.915
2021	49.315
2022	49.768

Como queremos calcular a média considerando $k = 3$, inicialmente calculamos a média dos valores relativos aos 3 primeiros anos, logo:

$$MM = \frac{Y_1 + Y_2 + Y_3}{k}$$

$$MM = \frac{45163 + 45998 + 46816}{3}$$

$$MM = \frac{137977}{3} = 45992,33$$

Para próxima média abandonamos a observação mais antiga, assim vamos realizar a média considerando os anos de 2014 até 2016:

$$MM = \frac{Y_2 + Y_3 + Y_4}{k}$$

$$MM = \frac{45998 + 46816 + 47311}{3}$$


$$MM = \frac{140125}{3} = 46708,33$$

Seguindo o mesmo raciocínio para os demais valores da série temos as seguintes médias:

Ano	Faturamento (R\$)	Média Móvel ($k = 3$)
2013	45.163	
2014	45.998	
2015	46.816	45.992,33
2016	47.311	46.708,33
2017	47.758	47.295,00
2018	48.164	47.744,33
2019	48.548	48.156,67

2020	47.915	48.209,00
2021	49.315	48.592,67
2022	49.768	48.999,33

No seguinte gráfico é indicado os valores da série temporal e a média móvel com ordem de três períodos:



As médias móveis enfocam somente os valores recentes, assim uma média móvel com um comprimento pequeno pode responder a rápidas mudanças numa série temporal. Já uma média móvel com um comprimento grande irá responder mais vagarosamente. Castanheira (2011) comenta que, quanto mais pontos utilizamos para o cálculo da média móvel, mais suave será a curva resultante. Um problema potencial com a média móvel é que as médias podem ser afetadas por valores atípicos, que são picos na série longe dos demais valores, contaminando todas as médias nas quais esse pico participa, espalhando, assim, sua influência sobre vários valores.

De acordo Sharpe, Veaux e Velleman (2011), geralmente as médias móveis são usadas acima de tudo como resumos de como uma série temporal está mudando. O comprimento selecionado depende do propósito da análise. Se o foco for um comportamento a longo prazo, uma média móvel mais longa é apropriada. Mas um analista interessado em mudanças a prazos mais curtos iria escolher um comprimento menor.

As empresas geralmente analisam as séries temporais para procurar padrões anteriores nos dados e para prever valores futuros, assim podem estar interessados em entender os padrões para:

- Planejar o estoque e a distribuição de produtos;
- Programar as contratações e a equipe de trabalho;
- Entender o impacto das estações ou de determinado período do ano nas vendas;
- Desenvolver campanhas de *marketing*;
- Prever lucros;
- Planejar estratégias para empresa.

De acordo com Sharpe, Veaux e Velleman (2011), o objetivo da maioria das análises das séries temporais é fornecer previsões de valores futuros. E como a previsão futura é valiosa para decisores em negócios, os métodos de séries temporais são amplamente usados. Segundo Souza et al. (2021), com os parâmetros estimados do modelo de séries temporais, podemos fazer previsões acerca de valores futuros da série, uma das grandes aplicações dos modelos. A qualidade das previsões depende do tipo de modelo ajustado, do quão longe se deseja prever, dos métodos inferenciais empregados no processo de estimação, entre outros fatores.

No tópico 4, estudamos o método da regressão e as médias móveis que podem ser utilizados na previsão de séries temporais. Segundo Sharpe, Veaux e Velleman (2011), os modelos de regressão são fáceis de usar para a previsão, porque eles nos dão uma fórmula. Os modelos baseados na regressão podem prever além do próximo período de tempo.

Vamos considerar o exemplo 1 do tópico 4, onde foi calculada a reta de regressão que mais se ajustava nos dados referentes as receitas brutas de uma determinada empresa, em bilhões de reais (R\$). Considerando a equação da reta é possível projetar as receitas brutas para o ano de 2023, substituindo o valor de x da equação por 14:

$$y = 16,3140 + 0,8429x$$

$$y = 16,3140 + 0,8429 \cdot 14$$


$$y = 16,3140 + 11,8006$$

$$y = 28,1146$$

Assim, para o ano de 2023 há uma previsão de receita bruta de 28,1146 bilhões de reais.

Obs.: lembrando que, para facilitar os cálculos, utilizamos valores codificados consecutivos de 0 a 13 para representar a variável x (ano codificado), assim continuamos a sequência para o ano de 2023.

Outro método estudado no tópico 4 foi as médias móveis, que podem ser usadas para obter uma previsão para um novo ponto no tempo considerando a última média encontrada da série. Assim, este método pode prever somente um período de tempo futuro, que é o tempo $= t + 1$. Considerando o exemplo 2 resolvido no tópico 4 que utiliza os últimos 10 anos de uma série de faturamento e calcula as médias considerando ordem igual a 3, podemos encontrar a previsão para o ano de 2023. Como a ordem das médias é igual a 3, utilizamos a média dos últimos três valores para encontrar a previsão:

$$MM = \frac{47915 + 49315 + 49768}{3} = 48.999,33$$

Logo, para o ano de 2023, há uma previsão de faturamento de R\$ 48.999,33.

Segundo Sharpe, Veaux e Velleman (2011), os modelos baseados na regressão estimam a tendência e as componentes sazonais pela regressão sobre o tempo e usam variáveis auxiliares para modelar o período sazonal. Eles podem incorporar variáveis exógenas para ajudar a modelar ciclos econômicos e outros fenômenos. E, diferente das médias móveis, eles podem prever um futuro mais longo.

De acordo com Sharpe, Veaux e Velleman (2011), sempre que modelamos uma série temporal, é natural perguntar quão bem o modelo se ajusta às séries. Uma pergunta relacionada é quão bem o modelo prevê as séries. Para modelos de alisamento, usamos o valor do modelo mais recente como o preditor para o próximo período de tempo. Sua escolha depende tanto da natureza dos seus dados quanto no que você espera aprender dos dados. Se o interesse for o erro que o modelo comete quando tenta estimar cada valor, podemos comparar o valor dos dados reais com a estimativa, encontrando um erro de previsão para cada tempo. Há diversas medidas de erro dentre as quais



podemos indicar a comparação gráfica, diagramas de dispersão, coeficiente de correlação, erro quadrático acumulado, raiz do erro médio quadrático (*RMSE*) e erro percentual médio absoluto (*MAPE*).

Saiba mais

Para entender mais sobre os métodos de previsão utilizando séries temporais, vamos acessar os seguintes *links* que apresentam algumas aplicações:

FARIA, E. L. et al. Previsão de Séries Temporais utilizando Métodos Estatísticos. **CBPF**, 2011. Disponível em: <http://cbpfindex.cbpf.br/publication_pdfs/NT00308.2011_01_04_11_12_17.pdf>. Acesso em: 16 ago. 2023.

DADOS em séries temporais: por que são importantes no Contas a Receber? **Receiv**, 18 dez. 2020. Disponível em: <<https://receiv.it/blog/dados-em-series-temporais-por-que-sao-importantes-no-contas-a-receber/>>. Acesso em: 16 ago. 2023.

CAMBUÍ, C. M. C. Aplicações de previsão de demanda por meio de séries temporais. **Revista de Gestão e Secretariado**, São Paulo, v. 14, n. 2, p. 1477-1490, 2023. Disponível em: <<https://ojs.revistagesec.org.br/secretariado/article/view/1627/800>>. Acesso em: 16 ago. 2023.

Com os avanços das técnicas de Inteligência Artificial (*IA*), é possível construir modelos cada vez mais precisos, capazes de gerar respostas cada vez mais assertivas aos tomadores de decisão.

Saiba mais

Métodos de Inteligência Artificial como as Redes Neurais estão sendo utilizados nas previsões de demanda por apresentarem menores erros em comparação com modelos tradicionais. Para entender mais sobre esse assunto, vamos acessar o seguinte *link*:

INTELIGÊNCIA artificial: aliada das estratégias de séries temporais. **Exame**, 29 abr. 2023. Disponível em: <<https://exame.com/future-of-money/inteligencia-artificial-aliada-das-estrategias-de-series-temporais/>>. Acesso em: 16 ago. 2023.

Vimos que a análise de séries temporais possui uma vasta aplicação em diferentes áreas. Nas empresas podemos utilizar, por exemplo, na análise do fluxo de estoque, programação de compras de matéria-prima, dimensionamento de vendas e campanhas de *marketing*. No mercado financeiro pode ser utilizada para responder algumas perguntas como: Será que a bolsa de valores vai subir? Será que a cotação do dólar vai cair? Podemos citar também, os dados econômicos de um país como o *IPCA* e o *PIB* que podem auxiliar nas tomadas de decisões do governo. Outro estudo é o realizado pela climatologia que observando a temperatura diária ou índice pluviométrico mensal podem prever o comportamento em longo prazo ajudando, por exemplo, na agricultura para o desenvolvimento de medidas protetivas contra desastres naturais e a tomar decisões como determinar a melhor hora de colher e plantar. Para entender melhor essas aplicações, faça uma pesquisa de uma série temporal e analise identificando os componentes que estudamos ao longo desta etapa.


NA PRÁTICA

Estudamos que a análise de séries temporais é uma técnica estatística essencial para entender padrões, tendências e comportamentos dos dados ao longo do tempo. Por meio dessa análise, é possível realizar previsões e tomar decisões estratégicas mais assertivas com base em informações confiáveis. Para praticar os assuntos estudados ao longo desta etapa, vamos resolver os seguintes exercícios:

Exercício 1


Observe as seguintes séries temporais e indique quais os componentes, estudados no Tópico 2, estão presentes em cada uma das séries.

a.




Observando a série apresentada é possível identificar a presença de uma tendência positiva e uma componente sazonal.

b.



Nesta série é possível identificar a presença de uma tendência e uma componente irregular.

c.



A série apresentada uma tendência positiva com uma curva ascendente não linear e uma componente sazonal.

Exercício 2

Considere a seguinte série que apresenta o patrimônio líquido (em bilhões de reais) de uma determinada empresa entre os anos de 2010 a 2020. Encontre os coeficientes da reta de mínimos quadrados e a previsão de tendência para os anos de 2021 e 2022.



Ano	Patrimônio (R\$ 1.000.000)
2010	30
2011	32
2012	32
2013	35
2014	37
2015	38
2016	42
2017	41
2018	44
2019	46
2020	47

Para iniciar vamos utilizar valores codificados consecutivos de 1 a 11 para representar a variável x (ano codificado). Para o coeficiente b precisamos realizar os cálculos de $x.y$, x^2 e encontrar os somatórios:

Ano	x	Patrimônio (R\$ 1.000.000)	$x.y$	x^2
2010	1	30	30	1
2011	2	32	64	4
2012	3	32	96	9
2013	4	35	140	16
2014	5	37	185	25
2015	6	38	228	36
2016	7	42	294	49
2017	8	41	328	64
2018	9	44	396	81
2019	10	46	460	100
2020	11	47	517	121
Total	66	424	2738	506

Com os dados da tabela, aplicamos a fórmula do b considerando $n = 11$ que é a quantidade de anos apresentados na tabela, após calculamos o coeficiente a e por fim encontramos a equação da reta:

$$b = \frac{n \sum x.y - \sum x. \sum y}{n \sum x^2 - [\sum x]^2}$$

$$b = \frac{11.2738 - 66.424}{11.506 - (66)^2}$$

$$b = \frac{2134}{1210} = 1,7636$$

$$a = \left[\frac{\sum y}{n} \right] - b \left[\frac{\sum x}{n} \right]$$

$$a = \left[\frac{424}{11} \right] - 1,7636 \left[\frac{66}{11} \right]$$

$$a = 38,5455 - 10,5816$$

$$a = 27,9639$$

Com os coeficientes encontramos a equação da reta que ajusta os dados:

$$y = a + bx$$

$$y = 27,9639 + 1,7636x$$

Utilizando a equação encontrada é possível encontrar a previsão para os anos de 2021 e 2022:

- 2021:

$$y = 27,9639 + 1,7636 \cdot 12$$

$$y = 27,9639 + 21,1632 = 49,1271$$

- 2022:

$$y = 27,9639 + 1,7636 \cdot 13$$

$$y = 27,9639 + 22,9268 = 50,8907$$

Exercício 3

O relatório de vendas de um determinado produto indicou os seguintes valores para os anos de 2015 até 2019. Utilize médias móveis de três anos para prever quais seriam as vendas em 2020.

Ano	Vendas
2015	18.546
2016	22.364
2017	22.413
2018	19.881
2019	26.670

Como a ordem das médias é igual a 3 anos, utilizamos a média dos últimos três valores para encontrar a previsão:

$$MM = \frac{22413 + 19881 + 26670}{3} = 22988$$

Nesta etapa, estudamos os principais conceitos envolvendo as Séries temporais, os diferentes componentes de uma série e os Métodos de Regressão e Médias Móveis. Estudamos que a tendência indica a direção, o crescimento ou decrescimento das observações ao longo do tempo. Os ciclos apresentam certo grau de regularidade para períodos maiores que um ano, a sazonalidade estabelece efeitos periódicos nos dados em curto prazo e as variações aleatórias ou irregulares indicam fenômenos que variam de forma aleatória. Vimos que as empresas geralmente analisam as séries temporais para procurar padrões anteriores nos dados e para prever valores futuros utilizando essas análises para tomar decisões estratégicas mais assertivas fazendo a diferença nas estratégias corporativas.

REFERÊNCIAS

ANÁLISE de séries temporais. **UFF**, 2022. Disponível em: <<http://labdge.uff.br/analise-de-series-temporais/>>. Acesso em: 16 ago. 2023.

CASTANHEIRA, N. P. **Matemática aplicada à economia**. Curitiba: Contentus, 2020.

_____. **Métodos quantitativos**. Curitiba: Ibpx, 2011.

MCCLAVE, J. T; BENSON P. G; SINCICH. T. **Estatística para administração e economia**. São Paulo: Pearson Prentice Hall, 2009.

PINTO, W. O. Previsão de séries temporais com redes neurais artificiais aplicada à demanda. **Monografias.com**, S.d. Disponível em: <<https://www.monografias.com/pt/trabalhos3/previsao-series-temporais-redes-neurais/previsao-series-temporais-redes-neurais2.shtml>>. Acesso em: 16 ago. 2023.

SHARPE, N. R; VEAUX, R. D; VELLEMAN, P. F. **Estatística aplicada**. Porto Alegre: Bookman, 2011.

SILVA, F. da. Introdução à previsão quantitativa. **Análise macro**, 10 mar. 2023. Disponível em: <<https://analisemacro.com.br/data-science/introducao-a-previsao-quantitativa/>>. Acesso em: 16 ago. 2023.

SIQUEIRA, D. Séries temporais: tipos de sazonalidade. **Alura**, 9 jun. 2021. Disponível em: <<https://www.alura.com.br/artigos/series-temporais-tipos-de-sazonalidade>>. Acesso em: 16 ago. 2023.

SOUZA, R. C; CAMARGO, M. E. **Análise e previsão de séries temporais: os modelos ARIMA**. Rio de Janeiro: Gráfica e Editora Regional, 2004.

SOUZA, A. R. S. et al. **Análise de séries temporais**. Porto Alegre: Sagah, 2021.